EVALUASI DAMPAK *DIGITAL HAIR REMOVAL* TERHADAP KINERJA ARSITEKTUR *LIGHTWEIGHT* CNN EFFICIENTNET-B0 DAN MOBILENETV2 DALAM KLASIFIKASI MELANOMA PADA CITRA DERMOSKOPI

TUGAS AKHIR

Diajukan untuk melengkapi tugas-tugas dan
memenuhi syarat-syarat guna memperoleh gelar Sarjana Komputer

Oleh:

SHOFIA NURUL HUDA
2208107010015

PROGRAM STUDI INFORMATIKA DEPARTEMEN INFORMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS SYIAH KUALA, BANDA ACEH
JULI, 2026

PENGESAHAN

EVALUASI DAMPAK *DIGITAL HAIR REMOVAL* TERHADAP KINERJA ARSITEKTUR *LIGHTWEIGHT* CNN EFFICIENTNET-B0 DAN MOBILENETV2 DALAM KLASIFIKASI MELANOMA PADA CITRA DERMOSKOPI

EVALUATION OF THE IMPACT OF DIGITAL HAIR REMOVAL ON THE PERFORMANCE OF LIGHTWEIGHT CNN EFFICIENTNET-B0 AND MOBILENETV2 IN MELANOMA CLASSIFICATION IN DERMOSCOPY IMAGES

Oleh:

Nama	: Shofia Nurul huda
NPM	: 2208107010015
Program Studi	: S1-Informatika

Menyetujui:

Pembimbing I,	Pembimbing II,
Kikye Martiwi Sukiakhy ST., M.Kom	Zulfan S.Si., M.Sc.
NIP. 198605202019032009	NIP. 198606022015041003

Mengetahui:

Dekan FMIPA, Universitas Syiah Kuala,	Koordinator Prodi S1 Informatika FMIPA, Universitas Syiah Kuala,
Prof. Dr. Taufik Fuadi Abidin, S.Si., M.Tech	Rasudin, S.Si., M.Info. Tech
NIP. 197010081994031002	NIP. 197410011999031001

Lulus Sidang Sarjana pada hari Selasa, 23 Juni 2026
Tugas Akhir disahkan pada hari Jum'at, 03 Juli 2026

PERNYATAAN BEBAS PLAGIASI

Saya yang bertanda tangan dibawah ini,

Nama lengkap	: Shofia Nurul Huda
Tempat/tanggal lahir	: Langsa/15 Januari 2005
NPM	: 2208107010015
Program Studi	: S1 Informatika
Jurusan	: Informatika
Fakultas	: Matematika dan Ilmu Pengetahuan Alam
Judul Tugas Akhir	: Evaluasi Dampak *Digital Hair Removal* Terhadap Kinerja Arsitektur *Lightweight* CNN Efficientnet-B0 Dan Mobilenetv2 Dalam Klasifikasi Melanoma Pada Citra Dermoskopi

Menyatakan dengan sesungguhnya bahwa Laporan Tugas Akhir saya dengan judul seperti di atas adalah **hasil karya saya sendiri** bersama dosen pembimbing dan **bebas plagiasi.**

Jika ternyata dikemudian hari terbukti bahwa Laporan Tugas Akhir merupakan hasil plagiasi, saya bersedia menerima sanksi yang berlaku di Universitas Syiah Kuala.

Banda Aceh, 03 Juli 2026
Yang menyatakan,

Shofia Nurul Huda
NPM. 2208107010015

SURAT PERNYATAAN

Yang bertanda tangan dibawah ini,

1. Nama : Shofia Nurul huda
   NPM : 2208107010015
   Departemen/Prodi : Informatika
   Status : Mahasiswa
2. Nama : Kikye Martiwi Sukiakhy ST., M.Kom
   NIP : 198605202019032009
   Departemen/Prodi : Informatika
   Status : Pembimbing I
3. Nama : Zulfan S.Si., M.Sc.
   NIP : 198606022015041003
   Departemen/Prodi : Informatika
   Status : Pembimbing II

Dengan ini menyatakan hasil penelitian Tugas Akhir yang berjudul **EVALUASI DAMPAK *DIGITAL HAIR REMOVAL* TERHADAP KINERJA ARSITEKTUR *LIGHTWEIGHT* CNN EFFICIENTNET-B0 DAN MOBILENETV2 DALAM KLASIFIKASI MELANOMA PADA CITRA DERMOSKOPI,** tidak dipublikasikan secara *full-text* di sistem ETD (*Electronic Theses and Dissertations*) Universitas Syiah Kuala hingga batas waktu 5 tahun dari tanggal kelulusan.

Demikian surat pernyataan ini dibuat dengan sebenarnya untuk dapat dipergunakan seperlunya.

Darussalam, 03 Juli 2026
Yang membuat pertanyaan,

Pembimbing I,	Pembimbing II,	Mahasiswa,
Kikye Martiwi Sukiakhy ST., M.Kom	Zulfan S.Si., M.Sc.	Shofia Nurul Huda
NIP. 198605202019032009	NIP. 198606022015041003	NPM. 2208107010015

Mengetahui:

Koordinator Prodi S1 Informatika FMIPA Universitas Syiah Kuala,	Koordinator TA,
Rasudin, S.Si., M.Info. Tech.	Sri Azizah Nazhifah, S.Kom., M.Sc.
NIP. 197410011999031001	NIP. 199304072024062003

ABSTRAK

Melanoma merupakan salah satu jenis kanker kulit yang berpotensi menyebabkan kematian apabila tidak terdeteksi sejak dini. Pemanfaatan *deep learning* pada citra dermoskopi telah menunjukkan potensi yang besar dalam membantu proses klasifikasi melanoma. Namun, keberadaan artefak rambut pada citra dermoskopi dapat mengganggu proses ekstraksi fitur dan memengaruhi kinerja model. Penelitian ini bertujuan untuk mengevaluasi dampak penerapan *Digital Hair Removal* (DHR) terhadap kinerja dua arsitektur *lightweight Convolutional Neural Network* (CNN), yaitu EfficientNet-B0 dan MobileNetV2. Dataset yang digunakan merupakan gabungan ISIC 2019 dan ISIC 2020 yang terdiri dari 23.114 citra benign dan malignant. Proses DHR dilakukan menggunakan metode *morphological black-hat* dan *inpainting Telea*. Empat skenario model dibangun, yaitu EfficientNet-B0 *Original*, EfficientNet-B0 *Hair Removed*, MobileNetV2 *Original*, dan MobileNetV2 *Hair Removed*. Seluruh model dilatih menggunakan *transfer learning* dengan bobot pra-latih ImageNet. Hasil penelitian menunjukkan bahwa MobileNetV2 *Original* memberikan performa terbaik dengan *accuracy* 87,02%, *precision* 0,6524, *recall* 0,8796, F1-*score* 0,7492, dan AUC-ROC 0,9433. Penerapan DHR memberikan dampak yang berbeda pada setiap arsitektur. Pada EfficientNet-B0, *accuracy* meningkat dari 83,28% menjadi 84,08%, sedangkan pada MobileNetV2 *accuracy* menurun dari 87,02% menjadi 59,98%. Hasil ini menunjukkan bahwa efektivitas DHR bergantung pada karakteristik arsitektur CNN yang digunakan. Sebagai implementasi, prototipe aplikasi web berbasis Flask berhasil dikembangkan untuk melakukan klasifikasi melanoma secara otomatis menggunakan model terbaik hasil penelitian.

Kata Kunci: Melanoma, *Digital Hair Removal*, EfficientNet-B0, MobileNetV2, Citra Dermoskopi, *Transfer Learning*.

ABSTRACT

Melanoma is one of the most aggressive types of skin cancer and can be life-threatening if not detected at an early stage. Deep learning approaches using dermoscopic images have shown significant potential in supporting melanoma classification. However, the presence of hair artifacts in dermoscopic images may interfere with feature extraction and affect model performance. This study aims to evaluate the impact of Digital Hair Removal (DHR) on the performance of two lightweight Convolutional Neural Network (CNN) architectures, namely EfficientNet-B0 and MobileNetV2. The dataset used is a combination of the ISIC 2019 and ISIC 2020 datasets, consisting of 23,114 benign and malignant dermoscopic images. The DHR process was performed using a combination of morphological black-hat transformation and Telea inpainting. Four experimental scenarios were developed: EfficientNet-B0 Original, EfficientNet-B0 Hair Removed, MobileNetV2 Original, and MobileNetV2 Hair Removed. All models were trained using transfer learning with ImageNet pretrained weights. The results show that MobileNetV2 Original achieved the best performance, with an accuracy of 87.02%, precision of 0.6524, recall of 0.8796, F1-score of 0.7492, and AUC-ROC of 0.9433. The application of DHR produced different effects on each architecture. For EfficientNet-B0, accuracy increased from 83.28% to 84.08%, whereas for MobileNetV2, accuracy decreased from 87.02% to 59.98%. These findings indicate that the effectiveness of DHR depends on the characteristics of the CNN architecture employed. As an implementation, a Flask-based web application prototype was successfully developed to perform automatic melanoma classification using the best-performing model.

Keywords: Melanoma, Digital Hair Removal, EfficientNet-B0, MobileNetV2, Dermoscopic Images, Transfer Learning.

KATA PENGANTAR

Puji syukur ke hadirat Allah SWT atas rahmat dan hidayah-Nya sehingga penyusun dapat menyelesaikan proposal penelitian berjudul "**Evaluasi Dampak *Digital Hair Removal* terhadap Kinerja *Lightweight* CNN EfficientNet-B0 dan MobileNetV2 dalam Klasifikasi Melanoma pada Citra Dermoskopi"** Proposal ini disusun sebagai bagian dari tugas Metodologi Penelitian untuk memenuhi persyaratan akademik di Informatika, Universitas Syiah Kuala.

Penelitian ini bertujuan untuk mengevaluasi dampak penerapan digital hair removal terhadap kinerja arsitektur *lightweight* CNN, yaitu EfficientNet-B0 dan MobileNetV2, dalam klasifikasi melanoma pada citra dermoskopi menggunakan dataset ISIC 2019 dan 2020. Penyusun menyadari bahwa penyusunan proposal ini tidak lepas dari bantuan berbagai pihak. Oleh karena itu, penyusun mengucapkan terima kasih kepada:

1. Fatilah Erni dan Ismul Huda, sebagai kedua orang tua penulis, abang Rahmat dan Chairul yang senantiasa memberikan dukungan penuh terhadap aktivitas dan kegiatan yang dilakukan penulis, baik secara moral maupun material, serta menjadi motivasi terbesar bagi penulis untuk menyelesaikan tugas akhir ini.
2. Prof. Dr. Taufik Fuadi Abidin, S.Si., M.Tech, sebagai Dekan FMIPA Universitas Syiah Kuala.
3. Bapak Dr. Nizamuddin, M.Info. Sc. selaku Ketua Departemen Informatika Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Syiah Kuala.
4. Bapak Rasudin, S.Si., M.Info. Tech. selaku Koordinator Program Studi S1 Informatika Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Syiah Kuala.
5. Ibu Kikye Martiwi Sukiakhy ST., M.Kom., selaku Dosen Pembimbing I dan Bapak Zulfan, S.Si., M.Sc., selaku Dosen Pembimbing II yang telah membimbing dan memberikan saran kepada penulis dalam penyesuaian tugas akhir ini.
6. Bapak Nazaruddin, S.Si., M. Eng.Sc., selaku Dosen Penguji I dan Ibu Junidar, S.Si, M.Kom., selaku Dosen Penguji II yang telah memberikan masukkan dan saran kepada penulis dalam penyelesaian tugas akhir ini.

7. Teman-teman "grup circle udh gk bertiga aja", Jihan Nabilah, Muhammad Bintang, Farhanul Khair, M. Nabil Maulana dan Ahmad Syah Ramadhan yang telah menemani dan memberi dukungan kepada penulis selama dua tahun terakhir perkuliahan di program studi Informatika USK.
8. DPH kabinet Adaptive dan kabinet Beyond yang senantiasa mendukung dan membersamai penulis.
9. Sahabat dan teman-teman seperjuangan dari program studi Informatika USK 2022 lainnya, telah memberikan dukungan moral yang luar biasa selama penulis menempuh pendidikan di program studi informatika USK.
10. Seluruh Dosen dan Staf di Departemen Informatika FMIPA, atas ilmu dan bimbingan yang diberikan kepada penulis selama perkuliahan, menjadi bagian tak terpisahkan dalam proses pembelajaran penulis.

Penulis mengakui adanya kekurangan dalam tulisan ini, baik dari aspek materi, metode, maupun bahasa yang digunakan. Oleh karena itu, penulis mengundang kritik dan saran yang konstruktif dari para pembaca untuk meningkatkan kualitas proposal ini. Penulis berharap bahwa tulisan ini dapat memberikan manfaat bagi banyak orang dan berkontribusi pada kemajuan ilmu pengetahuan.

Banda Aceh, 03 Juli 2026

Shofia Nurul Huda
NPM. 2208107010015

DAFTAR ISI

Halaman

Halaman Judul i
Halaman Pengesahan ii
Pernyataan Bebas Plagiasi iii
Surat Pernyataan iv
Abstrak v
Abstract vi
Kata Pengantar vii
Daftar Isi ix
Daftar Tabel xi
Daftar Gambar xii

BAB I PENDAHULUAN
1.1 Latar Belakang 1
1.2 Rumusan Masalah 3
1.3 Tujuan Penelitian 3
1.4 Manfaat Penelitian 4

BAB II TINJAUAN KEPUSTAKAAN
2.1 Melanoma 5
2.2 Dermoskopi 5
2.3 *Digital Hair Removal* 6
2.4 *Deep Learning* 7
2.5 *Convolutional Neural Network (CNN)* 8
2.6 Arsitektur EfficientNet-B0 8
2.7 Arsitektur MobileNetV2 9
2.8 Metrik Evaluasi 10
2.8.1 *Confusion Matrix* 11
2.8.2 *Accuracy Score* 11
2.8.3 *Precision* 12
2.8.4 *Recall* 12
2.8.5 *F1-Score* 13
2.8.6 Waktu Inferensi 13
2.8.7 Jumlah Parameter 13
2.9 Penelitian Terkait 14

BAB III METODE PENELITIAN
3.1 Waktu Dan Lokasi Penelitian 18
3.2 Alat Dan Bahan 18
3.2.1 Perangkat Keras 18
3.2.2 Perangkat Lunak 18
3.2.3 Dataset 19
3.3 Metode Penelitian 21
3.3.1 Identifikasi Masalah 22
3.3.2 Studi Literatur 23
3.3.3 Pengumpulan Data 23

3.3.4 Pra-pemrosesan Data 24
3.3.5 *Digital Hair Removal* 24
3.3.6 *Split Data* 25
3.3.7 Pelatihan Model 25
3.3.8 Evaluasi Model 26
3.3.9 Analisis Hasil 27
3.3.10 Implementasi dalam Bentuk Website 27

BAB IV HASIL DAN PEMBAHASAN
4.1 Eksplorasi Data 28
4.1.1 Distribusi Data 28
4.1.2 Visualisasi Sampel Data 29
4.1.3 Analisis Karakteristik Data 30
4.1.4 Pengecekan Duplikasi Data 32
4.2 Praproses Data 33
4.2.1 *Digital Hair Removal* 33
4.2.2 Pembagian Dataset 37
4.2.3 Normalisasi Citra 38
4.2.4 Augmentasi Data 39
4.3 Perancangan Arsitektur Model 40
4.3.1 Arsitektur EfficientNet-B0 41
4.3.2 Arsitektur MobileNetV2 44
4.4 Pengembangan Model 46
4.4.1 Konfigurasi Pelatihan 46
4.4.2 Pelatihan Model 47
4.5 Evaluasi Model 49
4.5.1 Evaluasi EfficientNet-B0 49
4.5.2 Evaluasi MobileNetV2 52
4.5.3 Perbandingan Efisiensi Komputasi 54
4.5.4 Perbandingan Keseluruhan Kinerja Model 56
4.6 Analisis Dampak Penerapan *Digital Hair Removal* 58
4.7 Implementasi Prototipe Aplikasi Web 61

BAB V KESIMPULAN DAN SARAN
5.1 Kesimpulan 64
5.2 Saran 65

DAFTAR KEPUSTAKAAN 67

DAFTAR TABEL

Halaman

Tabel 2.1. Penelitian terkait 14
Tabel 4.1. Distribusi kelas pada dataset 29
Tabel 4.2. Distribusi Data *train-validation-test split* 38
Tabel 4.3. Teknik augmentasi data pada training set 40
Tabel 4.4. Struktur Arsitektur EfficientNet-B0 42
Tabel 4.5. Struktur Arsitektur MobileNetV2 44
Tabel 4.6. Konfigurasi pelatihan 46
Tabel 4.7. Hasil eksperimen pelatihan 48
Tabel 4.8. Hasil Evaluasi EfficientNet-B0 pada Data Uji 49
Tabel 4.9. *Classification Report* EfficientNet-B0 *Original* 50
Tabel 4.10. *Classification Report* EfficientNet-B0 *Hair Removed* 50
Tabel 4.11. Hasil Evaluasi MobileNetV2 pada Data Uji 52
Tabel 4.12. *Classification Report* MobileNetV2 *Original* 52
Tabel 4.13. *Classification Report* MobileNetV2 *Hair Removed* 52
Tabel 4.14. Jumlah Parameter dan Efisiensi Komputasi 55
Tabel 4.15. Perbandingan Keseluruhan Kinerja Model 56
Tabel 4.16. Dampak *Digital Hair Removal* terhadap Kinerja Model 58

DAFTAR GAMBAR

Halaman

Gambar 2.1. Ilustrasi *Digital Hair Removal* (Quishpe-Usca *et al*., 2024) 7
Gambar 2.2. Arsitektur CNN (dimodifikasi dari Sutama *et al*., 2020)..... 8
Gambar 2.3. Arsitektur EfficientNet-B0 (Fajrina *et al*., 2024)..... 9
Gambar 2.4. Arsitektur MobileNetV2 (X. Wang & Li, 2023) 10
Gambar 3.1. Contoh citra dermoskopi setiap kelas 21
Gambar 3.2. Diagram alir penelitian menggunakan citra *original* 21
Gambar 3.3. Diagram alir penelitian menggunakan citra hasil *Digital Hair Removal* 22
Gambar 3.4. Ilustrasi rancangan proses *digital hair removal*..... 25
Gambar 4.1. Distribusi kelas pada dataset 28
Gambar 4.2. Perbandingan citra dermoskopi sebelum dan sesudah penerapan *digital hair removal* 30
Gambar 4.3. Distribusi dimensi gambar pada dataset original dan *hair removed*..... 31
Gambar 4.4. Distribusi intensitas piksel pada dataset original dan *hair removed*..... 32
Gambar 4.5. Alur proses *Digital Hair Remov*al menggunakan *black-hat transformation* dan *inpainting* 34
Gambar 4.6. Perbandingan citra sebelum dan sesudah penerapan *Digital Hair Removal* 35
Gambar 4.7. Contoh hasil augmentasi pada citra melanoma..... 40
Gambar 4.8. Arsitektur Model EfficientNet-B0 43
Gambar 4.9. Arsitektur Model MobileNetV2..... 45
Gambar 4.10. *Confusion Matrix* EfficientNet-B0 *Original*..... 50
Gambar 4.11. *Confusion Matrix* EfficientNet-B0 *Hair Removed* 51
Gambar 4.12. *Confusion Matrix* MobileNetV2 *Original* 53
Gambar 4.13. *Confusion Matrix* MobileNetV2 *Hair Removed*..... 53
Gambar 4.14. Dampak *Digital Hair Removal* terhadap Metrik Klasifikasi 59
Gambar 4.15. Tampilan halaman utama MelanoLens..... 62
Gambar 4.16. Tampilan hasil klasifikasi pada MelanoLens..... 62

BAB I
PENDAHULUAN

1.1 LATAR BELAKANG

Kanker kulit merupakan salah satu jenis kanker yang umum dijumpai di seluruh dunia dan menjadi masalah kesehatan global yang terus meningkat. Secara umum, kanker kulit dapat diklasifikasikan menjadi Basal Cell Carcinoma (BCC), Squamous Cell Carcinoma (SCC), dan melanoma. BCC dan SCC termasuk dalam kelompok *non-melanoma skin cancer* yang umumnya memiliki tingkat keganasan lebih rendah, sedangkan melanoma dikenal lebih berbahaya karena memiliki peluang lebih tinggi untuk bermetastasis atau menyebar ke bagian tubuh lain (University of Colorado Anschutz Cancer Center, 2024). Data Global Cancer Observatory (GLOBOCAN) tahun 2022 mencatat sekitar 331.722 kasus baru melanoma dengan 58.667 kematian di seluruh dunia. Meskipun angka kejadian melanoma di Indonesia relatif rendah, yaitu sekitar 1.716 kasus dengan *Age-Standardized Rate* (ASR) sebesar 0,42 per 100.000 penduduk, melanoma tetap menjadi ancaman serius karena tingkat fatalitasnya yang tinggi pada stadium lanjut (Arnold et al., 2022; Sung et al., 2021; Jütte et al., 2024).

Deteksi dini melanoma berperan penting dalam meningkatkan peluang keberhasilan penanganan. Salah satu metode yang banyak digunakan dalam praktik klinis adalah dermoskopi, yaitu teknik pencitraan non-invasif yang mampu menampilkan struktur morfologi lesi kulit secara lebih detail dibandingkan pemeriksaan visual biasa (Ertürk Zararsız et al., 2025). Seiring perkembangan teknologi kecerdasan buatan, sistem *Computer-Aided Diagnosis* (CAD) berbasis citra dermoskopi mulai banyak dikembangkan untuk membantu proses klasifikasi melanoma secara otomatis. Dalam hal ini, *Convolutional Neural Network* (CNN) menjadi pendekatan yang dominan karena mampu mengekstraksi fitur citra secara hierarkis dan otomatis.

Berbagai arsitektur CNN telah digunakan dalam klasifikasi citra medis, seperti ResNet, VGG, Inception, dan DenseNet. Namun, arsitektur tersebut umumnya memiliki ukuran model dan kebutuhan komputasi yang relatif besar, sehingga kurang

ideal untuk diterapkan pada perangkat dengan sumber daya terbatas. Oleh karena itu, arsitektur CNN ringan seperti EfficientNet-B0 dan MobileNetV2 menjadi alternatif yang menarik karena mampu menawarkan keseimbangan antara akurasi dan efisiensi komputasi. Beberapa penelitian menunjukkan bahwa EfficientNet-B0 dan MobileNetV2 memiliki performa yang baik dalam klasifikasi melanoma maupun citra medis lainnya (Iqbal et al., 2025; Nirupama & Virupakshappa, 2024).

Meskipun demikian, citra dermoskopi sering mengandung artefak visual yang dapat mengganggu proses klasifikasi, salah satunya adalah rambut pada permukaan kulit. Keberadaan rambut dapat menutupi area lesi penting dan mengaburkan karakteristik diagnostik yang dibutuhkan oleh model (Jütte et al., 2024). Selain itu, variasi pencahayaan, tekstur kulit, kemiripan visual antara lesi jinak dan ganas, serta ketidakseimbangan data pada dataset publik seperti ISIC juga dapat memengaruhi performa model (Al-Waisy et al., 2025; Liu et al., 2026). Oleh karena itu, tahap pra-pemrosesan citra menjadi bagian penting dalam membangun sistem klasifikasi melanoma yang lebih optimal.

Salah satu teknik pra-pemrosesan yang digunakan untuk mengatasi artefak rambut adalah *digital hair removal*. Teknik ini bertujuan mendeteksi dan menghilangkan rambut pada citra dermoskopi sehingga area lesi dapat terlihat lebih jelas. Beberapa penelitian menunjukkan bahwa penghilangan rambut secara digital dapat membantu meningkatkan kualitas citra dan berkontribusi terhadap kinerja klasifikasi melanoma (Jütte et al., 2024; Shahzaib et al., 2025). Namun, pengaruh langsung *digital hair removal* terhadap performa arsitektur CNN ringan seperti EfficientNet-B0 dan MobileNetV2 masih perlu dikaji secara lebih sistematis, khususnya dengan membandingkan kinerja model pada citra original dan citra hasil penghilangan rambut.

Berdasarkan permasalahan tersebut, penelitian ini berfokus pada evaluasi dampak *digital hair removal* terhadap kinerja arsitektur CNN ringan EfficientNet-B0 dan MobileNetV2 dalam klasifikasi melanoma pada citra dermoskopi. Penelitian ini membandingkan performa model pada dua skenario dataset, yaitu citra original dan citra hasil *digital hair removal*. Evaluasi dilakukan menggunakan metrik akurasi, presisi, recall, F1-score, confusion matrix, serta efisiensi komputasi. Hasil penelitian ini diharapkan dapat memberikan gambaran mengenai pengaruh tahap pra-pemrosesan

terhadap kinerja model ringan dan menjadi acuan dalam pengembangan sistem klasifikasi melanoma yang lebih efisien dan implementatif.

1.2 RUMUSAN MASALAH

Berdasarkan latar belakang mengenai tantangan deteksi dini melanoma, gangguan artefak rambut pada citra dermoskopi, serta kebutuhan akan model yang efisien, penelitian ini merumuskan masalah sebagai berikut:

1. Belum diketahui secara empiris dampak penerapan *digital hair removal* sebagai tahap pra-pemrosesan terhadap kinerja arsitektur *lightweight* CNN, yaitu EfficientNet-B0 dan MobileNetV2, dalam klasifikasi melanoma pada citra dermoskopi menggunakan dataset ISIC 2019 dan 2020.
2. Belum tersedia evaluasi kinerja yang komprehensif terhadap model klasifikasi melanoma yang mencakup metrik *accuracy*, *precision*, *recall*, F1-*score*, *confusion matrix*, serta aspek efisiensi komputasi.
3. Belum dilakukan analisis komparatif secara sistematis terhadap kinerja model pada dua kondisi citra, yaitu tanpa dan dengan *digital hair removal*, pada masing-masing arsitektur EfficientNet-B0 dan MobileNetV2.
4. Belum adanya prototipe berbasis web yang mengimplementasikan model terbaik hasil penelitian ini untuk mengklasifikasikan citra dermoskopi sebagai kanker atau tidak kanker.

1.3 TUJUAN PENELITIAN

Sebagaimana yang telah diuraikan pada rumusan masalah, tujuan dari penelitian ini adalah:

1. Mengimplementasikan empat skenario klasifikasi melanoma, yaitu EfficientNet-B0 dan MobileNetV2 pada kondisi citra tanpa *digital hair removal* serta EfficientNet-B0 dan MobileNetV2 pada kondisi citra dengan *digital hair removal*, menggunakan dataset ISIC 2019 dan 2020.
2. Melakukan evaluasi kinerja keempat model secara komprehensif menggunakan metrik *accuracy*, *precision*, *recall*, F1-*score*, *confusion matrix*, serta analisis efisiensi komputasi.

3. Menganalisis pengaruh penerapan *Digital Hair Removal* sebagai tahap pra-pemrosesan terhadap kinerja EfficientNet-B0 dan MobileNetV2 melalui perbandingan hasil klasifikasi pada kondisi citra sebelum dan sesudah *Digital Hair Removal*.
4. Membangun prototipe berbasis web menggunakan Flask yang mengintegrasikan model terbaik serta menampilkan hasil klasifikasi melanoma dalam bentuk melanoma atau non-melanoma.

1.4 MANFAAT PENELITIAN

Melalui penelitian ini penulis berharap dapat memberikan manfaat berupa:

1. Memberikan kontribusi dalam memahami pengaruh *digital hair removal* sebagai tahap pra-pemrosesan terhadap kinerja model *deep learning* dalam klasifikasi melanoma berbasis citra dermoskopi.
2. Menyediakan hasil perbandingan kinerja arsitektur EfficientNet-B0 dan MobileNetV2 pada kondisi citra original dan citra hasil Digital Hair Removal sebagai dasar pemilihan model yang optimal.
3. Menjadi referensi bagi penelitian selanjutnya dalam pengembangan metode pra-pemrosesan dan arsitektur *lightweight* CNN untuk klasifikasi melanoma.
4. Menghasilkan prototipe website sederhana berbasis Flask sebagai demonstrasi implementasi awal sistem pendukung diagnosis melanoma berbasis citra dermoskopi.

BAB II
TINJAUAN KEPUSTAKAAN

2.1 MELANOMA

Melanoma maligna merupakan salah satu jenis kanker kulit yang berasal dari sel penghasil pigmen kulit, yaitu melanosit, yang berada di epidermis. Dibandingkan dengan Sebagian besar kanker kulit *non-melanoma*, melanoma jauh lebih agresif. Sel kanker ini mampu menginvasi jaringan sekitar dan menyebar ke organ lain dengan cepat, sehingga keterlambatan diagnosis dan pengobatan dapat meningkatkan risiko kematian (Sung *et al*., 2021). Dalam praktik klinis, pembeda penting antara melanoma (ganas) dan nevus (tahi lalat jinak) didasarkan pada perubahan morfologi dan pola pigmentasi, dimana melanoma cenderung menunjukkan asimetri, batas tidak beraturan, variasi warna dan ukuran yang bertambah (prinsip yang diringkas dalam aturan ABCD (*Asymmetry, Border, Color, Diameter*)) sedangkan nevus biasanya mempertahankan simetri, batas halus, warna homogen, dan diameter kecil (Kittler, 2021). Pentingnya deteksi dini juga terlihat dari data epidemiologi. Menurut laporan IARC, setiap tahun terdapat ratusan ribu kasus melanoma baru di seluruh dunia, dengan jumlah kematian yang mencapai puluhan ribu (Ferlay, 2024). Kondisi ini menunjukkan bahwa upaya skrining dan penilaian awal yang efektif sangat dibutuhkan. Oleh karena itu, penggunaan alat bantu berbasis citra dapat menjadi solusi yang membantu proses deteksi lebih awal, sehingga diharapkan mampu menekan angka kematian dan mengurangi beban layanan kesehatan.

2.2 DERMOSKOPI

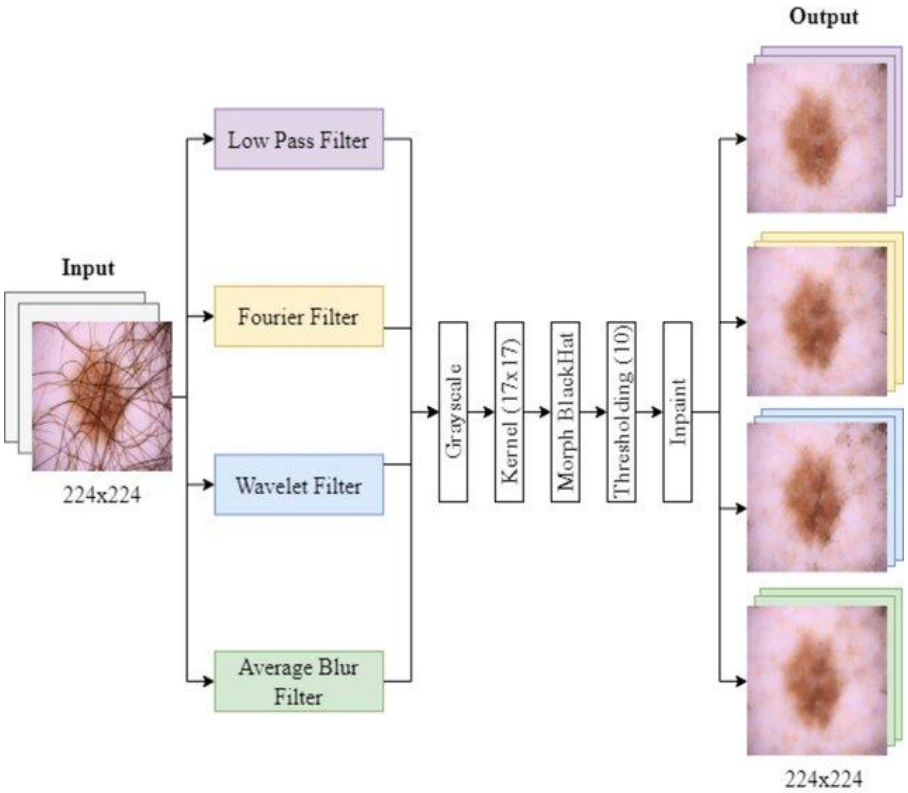
Dermoskopi merupakan teknik pencitraan non-invasif yang meningkatkan kemampuan visual klinisi untuk menilai struktur subepidermal dengan pembesaran dan penerangan khusus. Dermoskop memungkinkan observasi pola pigmen, jaringan vaskular, dan struktur mikroskopik lain yang tidak tampak pada pemeriksaan kasat mata, sehingga meningkatkan sensitivitas dan spesifisitas diagnosis melanoma bila dibandingkan inspeksi biasa (Kittler, 2021). Namun demikian, citra dermoskopi yang diambil di lingkungan klinik sering kali menyertakan artefak yang menurunkan

kualitas informasi visual. Artefak umum meliputi rambut yang menutupi area lesi, gelembung cairan atau gel kontak, pantulan cahaya dari permukaan dermoskop, dan bekas penggaris atau marker klinis. Artefak-artefak ini dapat mengacaukan ekstraksi fitur oleh pengamat manusia maupun sistem otomatis berbasis pembelajaran mesin sehingga menurunkan akurasi diagnostik (Delibasis *et al*., 2023).

Karena artefak tersebut memengaruhi baik diagnosis klinis maupun performa algoritma otomatis, langkah pra-pemrosesan yang tepat menjadi jembatan penting antara citra mentah yang diambil di lapangan dan keputusan diagnostik yang dapat diandalkan. Oleh karena itu, teknik *digital hair removal* dijadikan fokus utama guna meningkatkan kualitas citra dermoskopi sebelum dianalisis lebih lanjut.

2.3 *DIGITAL HAIR REMOVAL*

Digital Hair Removal (DHR) adalah rangkaian teknik pra-pemrosesan yang dirancang untuk mendeteksi dan menghapus piksel-piksel rambut pada citra dermoskopi, sehingga area lesi yang semula tertutup garis-garis gelap kembali merepresentasikan struktur kulit yang sebenarnya. Keberadaan rambut pada citra dermoskopi merupakan salah satu sumber noise yang signifikan dan dapat menurunkan kinerja sistem analisis otomatis. Menurut Delibasis *et al*. (2023), rambut yang melintang di atas lesi dapat mengganggu proses ekstraksi fitur dan berdampak pada penurunan akurasi klasifikasi melanoma, sehingga penghilangan rambut menjadi langkah pra-pemrosesan yang penting sebelum analisis lanjutan dilakukan. Berbagai metode telah dikembangkan, mulai dari pendekatan klasik seperti DullRazor berbasis operasi morfologi hingga pendekatan berbasis deep learning untuk segmentasi rambut. Secara umum, alur metode hair removal terdiri dari tahap segmentasi rambut, post-processing morfologi, dan proses inpainting untuk menghasilkan citra bebas rambut. Ilustrasi *hair removal* dapat dilihat pada gambar 2.1.



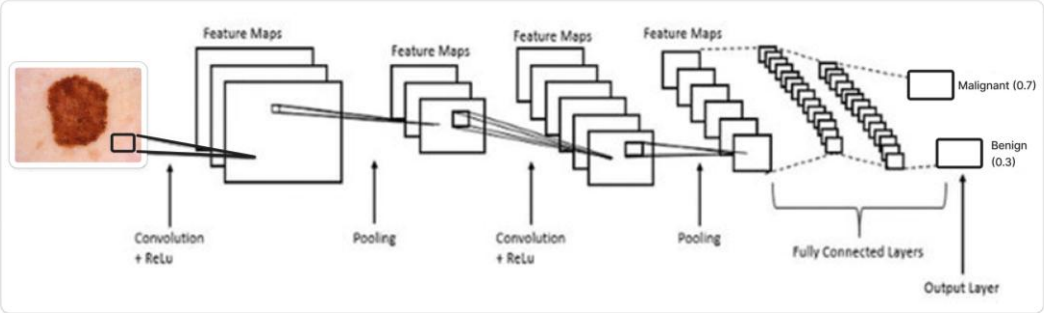
Gambar 2.1. Ilustrasi *Digital Hair Removal* (Quishpe-Usca *et al*., 2024)

2.4 *DEEP LEARNING*

Deep learning merupakan cabang dari *machine learning* yang menggunakan arsitektur jaringan saraf tiruan berlapis banyak (*deep neural networks*) untuk mempelajari representasi fitur secara hierarkis dari data mentah (Mienye & Swart, 2024). Tiap lapisan jaringan memproses data secara berjenjang, memungkinkan model menangkap pola kompleks dalam citra (misalnya pola pigmen melanoma) tanpa perlu ekstraksi fitur manual. Saat ini *deep learning* banyak digunakan dalam bidang biomedis, termasuk analisis citra medis dan dermatologi, karena kemampuannya dalam mengolah data berskala besar untuk diagnosis otomatis (Weiss *et al*., 2022). Pendekatan ini telah menjadi standar dalam segmentasi dan klasifikasi citra medis karena menunjukkan performa yang tinggi serta kemampuan generalisasi yang baik ketika dikombinasikan dengan *transfer learning* pada dataset terbatas.

2.5 *CONVOLUTIONAL NEURAL NETWORK (CNN)*

Convolutional Neural Network (CNN) adalah keluarga arsitektur deep learning yang dirancang untuk mengolah data berstruktur grid seperti citra, melalui lapisan konvolusi yang berfungsi mengekstraksi fitur spasial dari input secara otomatis. CNN memiliki blok utama berupa lapisan konvolusi yang menangkap pola lokal seperti tepi dan tekstur, lapisan pooling yang mereduksi dimensi untuk efisiensi komputasi, dan lapisan fully connected yang menyintesis fitur menjadi prediksi akhir. Struktur ini memungkinkan CNN untuk belajar hierarki fitur dari tingkat rendah ke tingkat tinggi tanpa perlu rekayasa fitur manual, sehingga sangat efektif dalam computer vision dan tugas analisis citra medis. CNN telah menjadi arsitektur state-of-the-art dalam analisis citra medis karena kemampuannya menangani kompleksitas data medis dan menghasilkan representasi fitur yang kuat untuk klasifikasi, segmentasi, dan deteksi penyakit, termasuk dermatologi dan lesi kulit. CNN juga terus berkembang melalui berbagai arsitektur modern seperti ResNet, U-Net, dan EfficientNet yang disesuaikan untuk tugas-tugas spesifik dalam domain medis. Sebagai contoh, CNN bisa secara otomatis mempelajari pola hierarkis pada citra dermoskopi untuk membedakan fitur lesi normal dan melanoma (Gao *et al*., 2025; Mienye *et al*., 2025).



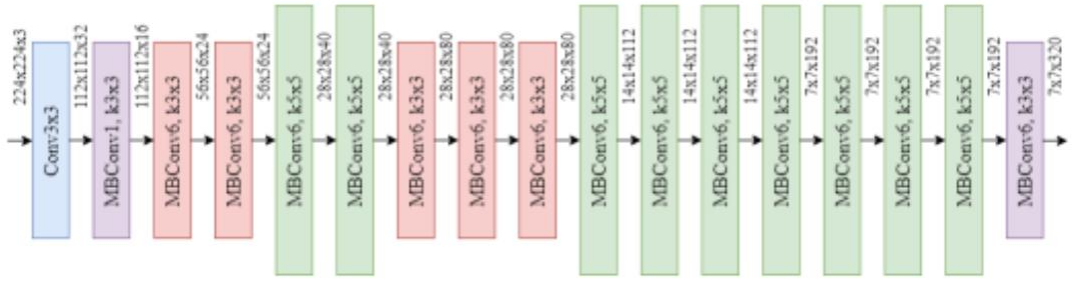
Gambar 2.2. Arsitektur CNN (dimodifikasi dari Sutama *et al*., 2020)

2.6 ARSITEKTUR EFFICIENTNET-B0

EfficientNet-B0 adalah varian dasar dari keluarga arsitektur EfficientNet yang dikembangkan oleh tim Google AI (Mingxing Tan dan Quoc V. Le) pada tahun 2019 dengan fokus pada keseimbangan antara akurasi dan efisiensi komputasi. Arsitektur ini menggunakan metode *compound scaling* yang secara sistematis menyeimbangkan dimensi kedalaman (*depth*), lebar jaringan (*width*), dan resolusi gambar (*resolution*)

menggunakan satu koefisien penskalaan tunggal (ϕ) (Fajrina *et al*., 2024; Pratiwi Tentriajaya & Wijayakusuma, 2025). Penskalaan ini memastikan model dapat menangkap detail gambar yang lebih kaya tanpa pemborosan sumber daya komputasi, sehingga sangat ideal untuk tugas klasifikasi citra medis yang kompleks namun tetap ringan untuk dijalankan (Pratiwi Tentriajaya & Wijayakusuma, 2025).

Struktur inti EfficientNet-B0 terdiri dari tujuh blok utama *Mobile Inverted Bottleneck* (MBConv) yang memanfaatkan teknik *Depthwise Separable Convolution* untuk mengurangi jumlah parameter secara signifikan tanpa menurunkan performa. Blok ini juga dilengkapi dengan fungsi aktivasi *Swish* dan mekanisme *Squeeze-and-Excitation* untuk meningkatkan representasi fitur tekstur yang krusial. Di akhir jaringan, lapisan *Global Average Pooling* dan *Dropout* digunakan untuk merangkum informasi spasial serta mencegah risiko *overfitting* (Fajrina *et al*., 2024; Pratiwi Tentriajaya & Wijayakusuma, 2025). Kemampuan model ini dalam mencapai akurasi tinggi pada dataset besar seperti ImageNet menjadikannya fondasi yang kuat untuk klasifikasi penyakit berbasis citra fundus retina maupun lesi kulit dermoskopi (Pratiwi Tentriajaya & Wijayakusuma, 2025).

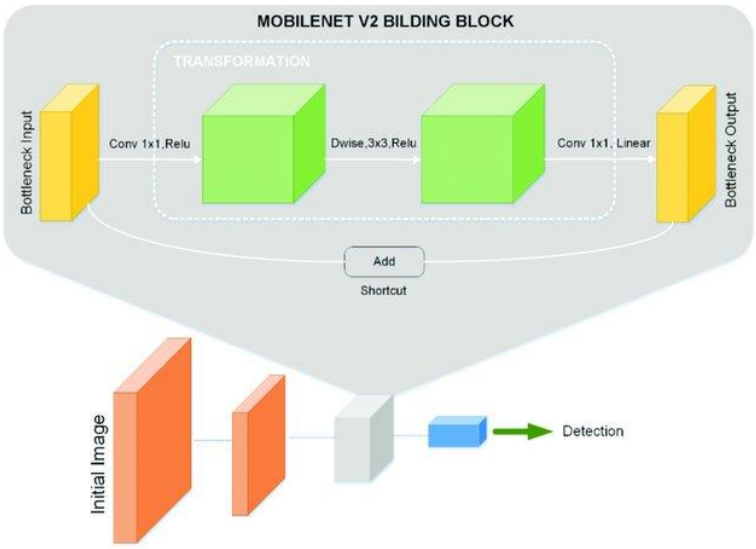


Gambar 2.3. Arsitektur EfficientNet-B0 (Fajrina *et al*., 2024)

2.7 ARSITEKTUR MOBILENETV2

MobileNetV2 merupakan arsitektur *Convolutional Neural Network* (CNN) ringan yang diperkenalkan oleh Google pada 2018 sebagai peningkatan dari MobileNetV1, dengan fokus utama pada efisiensi komputasi untuk aplikasi *mobile* dan *embedded devices*. Arsitektur ini menggunakan *depthwise separable convolutions* yang dikombinasikan dengan *inverted residual blocks* dan *linear bottlenecks* sebagai inovasi kunci dimana setiap blok dimulai dengan ekspansi dimensi melalui 1x1 *convolution*, diikuti *depthwise* 3x3 *convolution* untuk ekstraksi fitur spasial, dan

proyeksi linear 1x1 untuk pengurangan dimensi, serta *shortcut connections* untuk mempertahankan aliran gradien seperti pada ResNet. Struktur lengkapnya mencakup lapisan konvolusi awal (32 filter, stride 2), 17 inverted residual blocks, global average pooling, dan fully connected layer akhir, dengan total sekitar 3,5 juta parameter pada konfigurasi standar (Nirupama & Virupakshappa, 2024).



Gambar 2.4. Arsitektur MobileNetV2 (X. Wang & Li, 2023)

Keunggulan MobileNetV2 terletak pada pengurangan drastis FLOPs (sekitar 300 juta) dan parameter dibandingkan model konvensional, sambil meningkatkan akurasi ImageNet top-1 hingga 71-72% dan kecepatan inferensi 30-40% lebih cepat pada perangkat seperti Pixel phone, berkat ReLU6 yang robust terhadap kuantisasi dan fleksibilitas width/resolution multiplier (Askale *et al*., 2026; Nirupama & Virupakshappa, 2024). Alasan pemilihan MobileNetV2 untuk klasifikasi melanoma pada citra dermoskopi adalah kemampuannya mencapai akurasi tinggi (98-99%) pada dataset seperti HAM10000 dan ISIC dengan inferensi cepat, ideal untuk prototipe web Flask dengan resource-limited, serta superioritasnya dalam menangani noise rambut dibandingkan model lain seperti ShuffleNet. Dibandingkan EfficientNet-B0, MobileNetV2 menawarkan baseline efisien untuk perbandingan *lightweight* CNN dalam penelitian ini.

2.8 METRIK EVALUASI

Dalam pembelajaran mesin, metrik evaluasi adalah alat numerik yang digunakan dalam menilai kinerja suatu model untuk memprediksi atau

mengklasifikasikan data baru. Memilih metrik evaluasi yang tepat sangat penting dalam upaya untuk memastikan bahwa model berperilaku seperti yang di harapkan dan dalam menanggapi jenis masalah yang di hadapi, baik klasifikasi maupun regresi. Pada masalah klasifikasi, tujuan utama adalah mengklasifikasikan data ke dalam kategori atau kelas yang telah di tentukan. Dalam penelitian ini, metrik yang diterapkan untuk mengevaluasi performa model dalam mengklasifikasikan melanoma berdasarkan citra dermoskopi antara lain *confusion matrix, accuracy, precision, recall, F1-Score*, waktu inferensi, dan jumlah parameter.

2.8.1 *Confusion Matrix*

Confusion matrix adalah alat visualisasi yang membantu memahami kinerja model klasifikasi dengan menampilkan jumlah prediksi yang benar dan salah untuk masing-masing kelas. Matriks ini terdiri dari empat elemen utama: *True Positive* (TP) untuk prediksi positif yang benar, *True Negative* (TN) untuk prediksi negatif yang benar, *False Positive* (FP) untuk prediksi positif yang salah, dan *False Negative* (FN) untuk prediksi negatif yang salah. Confusion matrix sangat berguna untuk mengevaluasi model dalam kasus ketidakseimbangan kelas dan memahami pola kesalahan yang di buat oleh model (Powers, 2020).

2.8.2 *Accuracy Score*

Accuracy score merupakan salah satu metrik evaluasi yang paling sering digunakan dalam tugas klasifikasi. Nilai akurasi diperoleh dengan membandingkan jumlah prediksi yang benar terhadap keseluruhan prediksi yang dihasilkan oleh model. Metrik ini bekerja dengan baik ketika distribusi data antar kelas relatif seimbang. Namun, pada kondisi dataset yang tidak seimbang, akurasi dapat memberikan gambaran yang keliru. Sebagai contoh, apabila model selalu memprediksi seluruh data sebagai kelas mayoritas pada dataset yang sangat timpang, nilai akurasi tetap dapat terlihat tinggi meskipun model gagal mengidentifikasi kelas minoritas secara tepat.

$$Accuracy = \frac{TP + TN}{TP + FN + FP + TN} \tag{2.1}$$

Dengan:

Accuracy : tingkat kedekatan hasil prediksi dengan nilai sebenarnya

True Positive (TP) : jumlah prediksi kelas positif yang benar
True Negative (TN) : jumlah prediksi kelas negatif yang benar
False Positive (FP) : jumlah prediksi kelas positif yang salah
False Negative (FN) : jumlah prediksi kelas negatif yang salah

2.8.3 *Precision*

Precision atau presisi merupakan metrik evaluasi yang digunakan untuk menilai seberapa akurat prediksi positif yang dihasilkan oleh model. Nilai presisi diperoleh dengan membagi jumlah prediksi positif yang benar (*True Positive*) dengan seluruh prediksi yang diklasifikasikan sebagai positif, yaitu *True Positive* ditambah *False Positive*. Metrik ini menjadi sangat penting pada situasi di mana kesalahan positif palsu (*False Positive*) dapat menimbulkan konsekuensi serius, seperti pada diagnosis penyakit, sehingga diperlukan tingkat kepercayaan yang tinggi terhadap setiap prediksi positif yang dihasilkan. *Precision* dihitung menggunakan persamaan (2.2).

$$Precision = \frac{TP}{TP + FP} \tag{2.2}$$

Dengan:
Precision : tingkat ketepatan model dalam mengklasifikasikan data positif
True Positive (TP) : jumlah prediksi kelas positif yang benar
False Positive (FP) : jumlah prediksi kelas positif yang salah

2.8.4 *Recall*

Recall atau sensitivitas mengukur kemampuan model dalam mendeteksi seluruh kasus positif yang sebenarnya. Nilainya dihitung dengan membagi *True Positive* dengan total kasus positif aktual (*True Positive* + *False Negative*). Metrik ini sangat penting ketika kesalahan negatif palsu (*False Negative*) lebih berbahaya, seperti pada deteksi kanker. *Recall* dihitung menggunakan Persamaan (2.3).

$$Recall = \frac{TP}{TP + FN} \tag{2.3}$$

Dengan:
Recall : ukuran banyak kasus positif benar dari seluruh data positif
True Positive (TP) : jumlah prediksi kelas positif yang benar
False Negative (FN) : jumlah prediksi kelas negatif yang salah

2.8.5 *F1-score*

F1-*score* merupakan rata-rata harmonik dari *precision* dan *recall* yang digunakan untuk menilai keseimbangan antara keduanya. Metrik ini terutama bermanfaat ketika dataset memiliki distribusi kelas yang tidak seimbang. Nilai F1-score berkisar antara 0 hingga 1, dimana nilai lebih tinggi menunjukan keseimbangan yang baik antara *precision* dan *recall*. F1-*score* dihitung menggunakan Persamaan (2.4).

$$F1 - score = \frac{2 \times Precision \times Recall}{Precision + Recall} \tag{2.4}$$

Dengan:

F1-*score*	: rata-rata harmonic *precision* dan *recall*
Precision	: tingkat ketepatan model dalam mengklasifikasikan data positif
Recall	: ukuran banyak kasus positif benar dari seluruh data positif

2.8.6 Waktu Inferensi

Waktu inferensi merupakan lamanya proses yang dibutuhkan model atau algoritma untuk menghasilkan prediksi setelah menerima data input. Nilai waktu inferensi diukur secara kuantitatif dan umumnya dinyatakan dalam satuan milidetik (ms).

2.8.7 Jumlah Parameter

Jumlah parameter merujuk pada keseluruhan bobot (*weights*) dan bias yang dipelajari model selama proses pelatihan. Semakin besar jumlah parameter, semakin tinggi kapasitas model dalam menangkap pola kompleks pada data, namun hal tersebut juga dapat meningkatkan risiko *overfitting* serta kebutuhan komputasi yang lebih besar. Sebaliknya, model dengan parameter yang lebih sedikit umumnya lebih efisien dari segi penyimpanan dan penggunaan memori. Oleh karena itu, jumlah parameter sering dijadikan sebagai salah satu indikator tingkat kompleksitas suatu arsitektur model.

2.9 PENELITIAN TERKAIT

Berbagai penelitian telah dilakukan dalam pengembangan sistem klasifikasi lesi kulit berbasis *deep learning*, khususnya pada citra dermoskopi dan citra medis lainnya. Penelitian-penelitian tersebut umumnya berfokus pada peningkatan performa model melalui optimalisasi arsitektur CNN, penerapan teknik *preprocessing*, serta integrasi *segmentation* dan *attention mechanism*. Untuk mempermudah perbandingan, penelitian-penelitian terkait dirangkum secara sistematis pada Tabel 2.1.

Tabel 2.1. Penelitian terkait

Peneliti & Tahun	Judul Penelitian	Metode / Arsitektur	Hasil
Iqbal *et al*., (2025)	*Utilizing deep learning algorithms for the early identification and categorization of skin cancer*	VGG16, Inception-V3, EfficientNet-B0	Hasil penelitian menunjukkan bahwa EfficientNet-B0 memperoleh performa terbaik dengan akurasi validasi sebesar 92% serta nilai *precision*, *recall*, dan F1-*score* masing-masing di atas 92%. Penelitian ini menegaskan keunggulan arsitektur EfficientNet dalam tugas klasifikasi melanoma dibandingkan arsitektur konvensional.
Nirupama & Virupakshappa, (2024)	*MobileNet-V2: An Enhanced Skin Disease*	MobileNetV2 + SE + ASPP +	Model yang diusulkan memperoleh akurasi hingga 98.6% pada

	Classification by Attention and Multi-Scale Features	Channel Attention	berbagai dataset, termasuk ISIC dan HAM10000. Penelitian ini menunjukkan bahwa *lightweight* CNN seperti MobileNetV2 dapat mencapai performa tinggi dengan integrasi *attention* dan *multi-scale feature extraction*.
(Jütte *et al*., 2024)	*Advancing dermoscopy through a synthetic hair benchmark dataset and deep learning-based hair removal*	U-Net untuk hair removal	Penelitian ini berfokus pada peningkatan kualitas citra melalui evaluasi metrik restorasi seperti SSIM dan MSE. Hasil eksperimen menunjukkan bahwa model yang diusulkan mampu mengungguli metode klasik seperti Dullrazor dalam mempertahankan struktur lesi.
Al-Waisy *et al*., (2025)	*A deep learning framework for automated early diagnosis and classification of skin*	*Preprocessing* (Blackhat + inpainting), segmentasi, *decision fusion*	Tahap *preprocessing* mencakup peningkatan kontras dan penghilangan rambut menggunakan metode morfologi *Blackhat*

	cancer lesions in dermoscopy images		dan *inpainting*. Model ini mencapai akurasi hingga 99.65% pada dataset ISIC 2019.
Shahzaib *et al*., (2025)	*Hair removal and lesion segmentation of dermoscopic images for classification of skin cancer using deep neural networks*	Deep Residual U-Net + TELEA + DenseNet169	Eksperimen bertahap menunjukkan bahwa penerapan *hair removal* meningkatkan akurasi klasifikasi dari 92.28% menjadi 94.81%.
Ummah *et al*., (2022)	*EFFECT OF IMAGE PRE-PROCESSING METHOD ON CONVOLUTIONAL NEURAL NETWORK CLASSIFICATION OF COVID-19 CT SCAN IMAGES*	ResNet50 + MCLAHE	Dalam penelitian ini, akurasi ResNet50 meningkat dari 86.40% pada citra tanpa *preprocessing* menjadi 91.60% setelah penerapan MCLAHE. Hasil ini menegaskan bahwa kualitas citra *input* memiliki pengaruh signifikan terhadap kemampuan ekstraksi fitur CNN.

Berdasarkan tinjauan literatur di atas, dapat disimpulkan bahwa sebagian besar penelitian berfokus pada peningkatan performa melalui optimalisasi arsitektur atau pengembangan metode *hair removal* secara terpisah. Namun, belum terdapat penelitian yang secara sistematis mengevaluasi dampak *digital hair removal* terhadap performa arsitektur *lightweight* CNN, khususnya EfficientNet-B0 dan MobileNetV2, dalam klasifikasi melanoma pada citra dermoskopi. Selain itu, belum banyak

penelitian yang menganalisis pengaruh *preprocessing* terhadap efisiensi komputasi model, seperti jumlah parameter, dan waktu inferensi.

Oleh karena itu, penelitian ini bertujuan untuk mengisi celah tersebut dengan melakukan evaluasi eksperimental terhadap pengaruh *digital hair removal* terhadap kinerja dua arsitektur *lightweight* CNN dalam klasifikasi melanoma, baik dari aspek akurasi maupun efisiensi komputasi.

BAB III
METODE PENELITIAN

3.1 WAKTU DAN LOKASI PENELITIAN

Penelitian tugas akhir dilaksanakan di Laboratorium Sistem Informasi dan Database Gedung Fakultas Matematika dan Ilmu Pengetahuan Alam (FMIPA), Blok A Lantai 3, Universitas Syiah Kuala. Pelaksanaan penelitian ini berlangsung selama kurang lebih 3 bulan yang terhitung dari bulan Februari 2026 sampai dengan April 2026.

3.2 ALAT DAN BAHAN

Alat dan Bahan yang akan digunakan pada penelitian ini terdiri dari perangkat keras (*hardware*) dan perangkat lunak (*software*).

3.2.1 Perangkat Keras

Perangkat keras yang digunakan dalam penelitian ini adalah laptop Lenovo ThinkPad T14, dengan spesifikasi Processor Intel(R) Core(TM) i7-10610U CPU @ 1.80GHz (2.30 GHz), dengan RAM 24 GB.

3.2.2 Perangkat Lunak

- Sistem operasi Windows 11
- Text Editor Visual Studio Code
- Kaggle Notebook
- Python 3.10.11
- *Library* tensorflow 2.16.1
- *Library* opencv-python 4.9.0.80
- *Library* pandas 2.2.2
- *Library* numpy 1.26.4
- *Library* matplotlib 3.9.2
- *Library* scikit-learn 1.5.2
- *Library* Flask 3.0.0

- *Library* tqdm 4.67.1
- *Library* pillow 10.4.0
- *Library* seaborn 0.13.2
- *Library* torch 2.2.2

3.2.3 Dataset

Dataset yang digunakan dalam penelitian ini diperoleh dari *International Skin Imaging Collaboration* (ISIC) Archive, yaitu repositori terbuka yang menyediakan citra dermoskopi untuk keperluan penelitian analisis lesi kulit dan deteksi melanoma berbasis kecerdasan buatan. Data yang dimanfaatkan merupakan gabungan dari *ISIC 2019 Training Dataset* dan *ISIC 2020 Challenge Training Dataset*, yang diakses melalui *Application Programming Interface* (API) resmi ISIC Archive.

ISIC 2019 Training Dataset merupakan hasil agregasi dari beberapa sumber utama, yaitu *BCN_20000 Dataset* milik *Department of Dermatology, Hospital Clínic de Barcelona*; *HAM10000 Dataset* yang dikembangkan oleh *ViDIR Group, Department of Dermatology, Medical University of Vienna*; serta *MSK Dataset* yang sebelumnya digunakan dalam ISIC Challenge. Berdasarkan ketentuan lisensi *Creative Commons Attribution-Non Commercial 4.0 International License* (*CC-BY-NC 4.0*), penggunaan dataset ini untuk publikasi ilmiah mewajibkan pencantuman sitasi resmi dari masing-masing sumber, termasuk publikasi oleh Tschandl *et al*., (2018) untuk HAM10000, Codella *et al*., (2018) untuk ISIC Challenge, serta Hernández-Pérez *et al*., (2024) untuk BCN_20000.

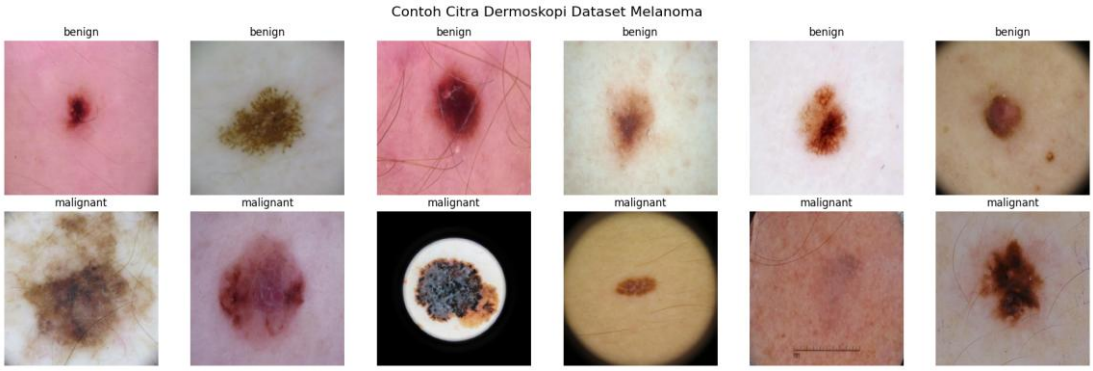
Sementara itu, *ISIC 2020 Challenge Training Dataset* merupakan bagian dari *SIIM-ISIC 2020 Challenge Dataset* yang dikembangkan oleh ISIC dan melibatkan berbagai institusi, seperti *Hospital Clínic de Barcelona*, *Medical University of Vienna*, *Memorial Sloan Kettering Cancer Center*, *Melanoma Institute Australia*, *The University of Queensland*, serta *University of Athens Medical School*. Dataset ini juga berada di bawah lisensi *CC-BY-NC 4.0* dan harus disitasi sesuai publikasi Rotemberg *et al*., (2021) dalam jurnal *Scientific Data*.

Pada tahap awal, jumlah data mentah yang diperoleh mencapai 25.331 citra dari ISIC 2019 dan 33.126 citra dari ISIC 2020, sehingga total keseluruhan berjumlah 58.457 citra dermoskopi. Seluruh metadata dari kedua dataset kemudian dibaca dan digabungkan menjadi satu kesatuan untuk mempermudah proses pengelolaan dan

penyaringan data. Karena penelitian ini berfokus pada klasifikasi melanoma secara biner, dilakukan beberapa tahapan seleksi data. Pertama, hanya citra dengan atribut *image_type = dermoscopic* yang dipertahankan, sehingga seluruh data yang digunakan benar-benar berupa citra dermoskopi. Kedua, dilakukan penyaringan berdasarkan atribut *diagnosis_1*, dengan memilih dua kategori utama, yaitu "Benign" dan "Malignant". Ketiga, citra difilter berdasarkan atribut *melanocytic = True* untuk memastikan bahwa lesi yang dianalisis merupakan lesi melanocytic dan relevan terhadap klasifikasi melanoma.

Setelah seluruh tahapan penyaringan selesai, diperoleh total 23.114 citra dermoskopi, yang terdiri atas 18.020 citra *benign* dan 5.094 citra *malignant*. Selanjutnya, label kelas dipetakan ke dalam bentuk numerik untuk kebutuhan pelatihan model, yaitu *benign* sebagai label 0 dan *malignant* sebagai label 1. Seluruh citra kemudian disusun ulang dalam struktur folder terpisah berdasarkan kelas guna mempermudah proses pemanggilan data pada tahap pelatihan model *deep learning*.

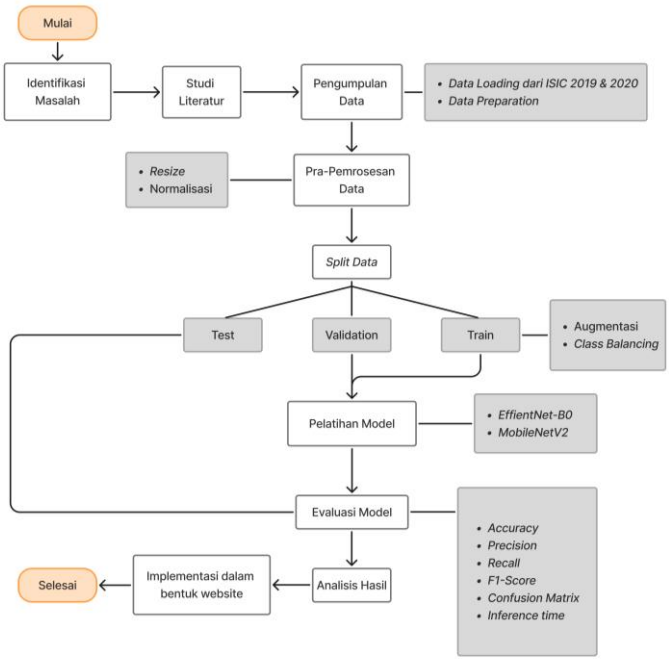
Dataset ini dipilih karena memiliki jumlah data yang relatif besar, variasi kondisi klinis yang luas, serta kualitas citra dermoskopi yang baik. Selain itu, ISIC merupakan dataset standar internasional yang banyak digunakan dalam penelitian klasifikasi melanoma berbasis *deep learning*, sehingga memungkinkan hasil penelitian ini dibandingkan secara relevan dengan penelitian terdahulu. Penggunaan dataset dari dua tahun berbeda yaitu 2019 dan 2020 juga meningkatkan keberagaman distribusi data dan membantu model dalam mempelajari karakteristik lesi kulit yang lebih representatif. Dataset yang telah melalui proses penggabungan, penyaringan, dan pelabelan tersebut selanjutnya digunakan dalam tahap pelatihan dan pengujian arsitektur *EfficientNet-B0* dan *MobileNetV2* untuk mengevaluasi dampak *digital hair removal* terhadap kinerja klasifikasi melanoma pada citra dermoskopi.



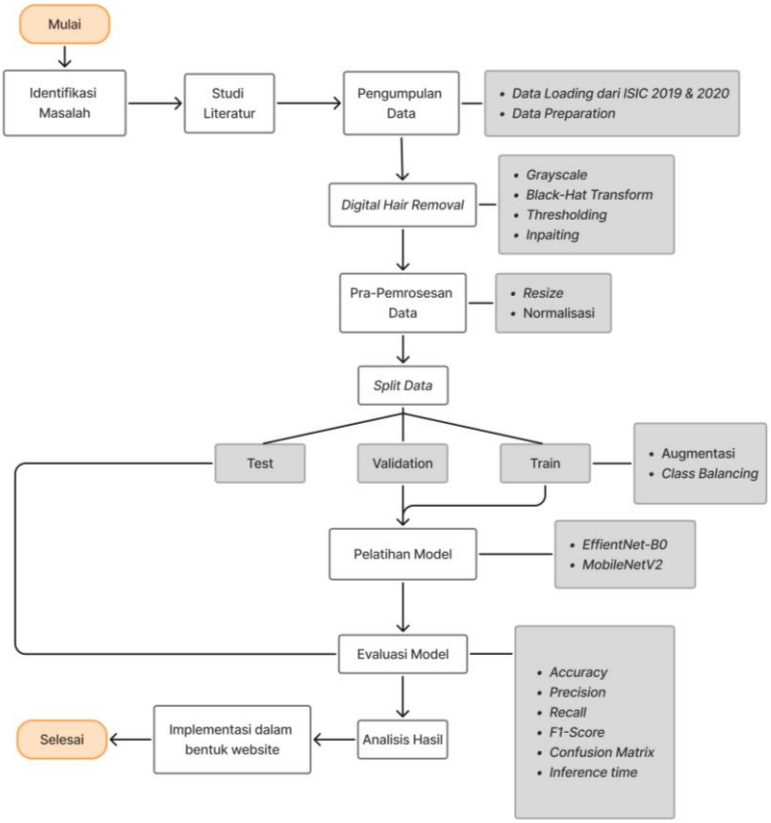
Gambar 3.1. Contoh citra dermoskopi setiap kelas

3.3 METODE PENELITIAN

Metode penelitian dirancang untuk mencapai tujuan dalam mengevaluasi dampak *hair removal* terhadap kinerja dua model *deep learning* serta membandingkan performa dan efisiensi kedua model yaitu *EfficientNet-B0* dan *MobileNetV2* dalam klasifikasi Melanoma. Penelitian ini menggunakan dua skenario eksperimen, yaitu skenario tanpa penerapan Digital Hair Removal dan skenario dengan penerapan Digital Hair Removal. Oleh karena itu, alur penelitian disajikan dalam dua diagram alir yang ditunjukkan pada Gambar 3.2 dan Gambar 3.3.



Gambar 3.2. Diagram alir penelitian menggunakan citra *original*



Gambar 3.3. Diagram alir penelitian menggunakan citra hasil *Digital Hair Removal*

3.3.1 Identifikasi Masalah

Tahap identifikasi masalah dilakukan untuk menentukan permasalahan utama yang menjadi fokus penelitian. Dalam klasifikasi melanoma berbasis citra dermoskopi, keberadaan artefak rambut merupakan salah satu faktor yang berpotensi mengganggu proses ekstraksi fitur oleh model deep learning. Rambut yang melintang di atas lesi dapat menutupi struktur pigmen, tepi lesi, serta pola vaskular yang penting dalam proses identifikasi melanoma. Kondisi ini dapat memengaruhi performa model, khususnya pada arsitektur *lightweight* CNN yang memiliki kapasitas parameter lebih terbatas dibandingkan model berukuran besar. Berdasarkan permasalahan tersebut, penelitian ini berfokus pada evaluasi apakah penerapan *digital hair remova*l dapat meningkatkan kinerja arsitektur EfficientNet-B0 dan MobileNetV2 dalam membedakan lesi *benign* dan *malignant*. Selain itu, penelitian ini juga mempertimbangkan aspek efisiensi komputasi untuk mengetahui apakah penerapan hair removal memengaruhi kompleksitas model. Oleh karena itu, penelitian ini

dilakukan melalui penerapan dua arsitektur *lightweight* CNN pada dua skenario data untuk mengevaluasi dampak *digital hair removal* terhadap kinerja klasifikasi.

3.3.2 Studi Literatur

Studi literatur pada penelitian ini dilakukan dengan menelaah berbagai buku, jurnal ilmiah, artikel, dan penelitian terdahulu yang berkaitan dengan klasifikasi melanoma menggunakan pendekatan *deep learning*. Kajian difokuskan pada arsitektur *Convolutional Neural Network* (CNN), khususnya arsitektur lightweight seperti EfficientNet-B0 dan MobileNetV2, serta teknik pra-pemrosesan citra dermoskopi termasuk *digital hair removal*. Pemahaman terhadap literatur tersebut menjadi dasar dalam menentukan metode, strategi eksperimen, serta parameter pelatihan yang digunakan dalam penelitian ini. Selain itu, studi literatur juga membantu dalam mengidentifikasi celah penelitian (*research gap*) yang mendasari evaluasi dampak *digital hair removal* terhadap kinerja arsitektur *lightweight* CNN dalam klasifikasi melanoma.

3.3.3 Pengumpulan Data

Data yang digunakan dalam penelitian ini diperoleh dari ISIC Archive, yaitu ISIC 2019 Training Dataset dan ISIC 2020 Challenge Training Dataset. Kedua dataset diunduh melalui API resmi ISIC dan kemudian digabungkan. Dataset tersebut berada di bawah lisensi Creative Commons Attribution-Non Commercial 4.0 dan telah banyak digunakan dalam penelitian klasifikasi melanoma. Setelah proses penggabungan, dilakukan penyaringan berdasarkan metadata untuk memilih citra dengan tipe *dermoscopic*, diagnosis_1 yang termasuk dalam kategori “Benign” dan “Malignant”, serta atribut *melanocytic* bernilai *True*. Proses ini bertujuan untuk memastikan bahwa dataset sesuai dengan fokus klasifikasi melanoma secara biner. Hasil penyaringan menghasilkan 23.114 citra, yang terdiri dari 18.020 citra *benign* dan 5.094 citra *malignant*. Dataset ini kemudian disusun dalam dua kelas untuk digunakan dalam tahap eksperimen.

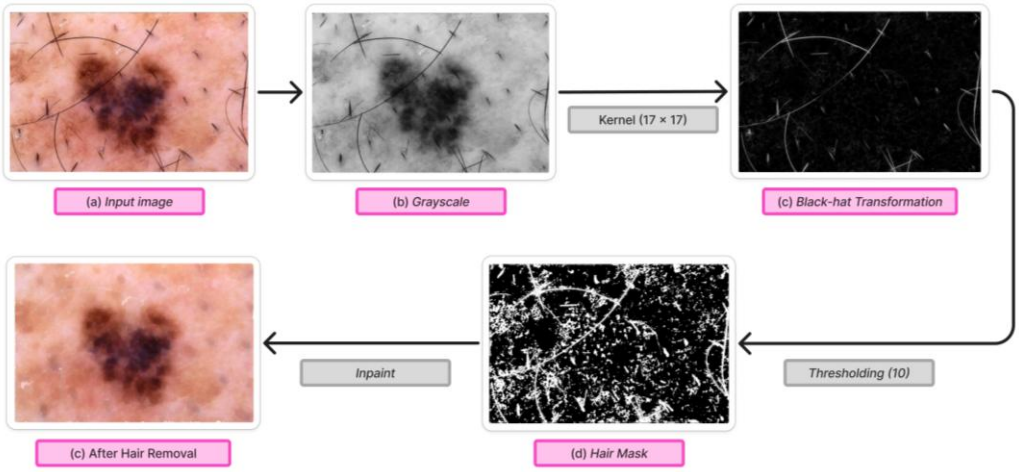
3.3.4 Pra-pemrosesan Data

Pra-pemrosesan data dilakukan untuk menyiapkan citra sebelum digunakan dalam pelatihan model. Tahapan ini meliputi penyesuaian ukuran citra menjadi 224 x 224 piksel agar sesuai dengan input arsitektur EfficientNet-B0 dan MobileNetV2, serta normalisasi nilai piksel ke dalam rentang 0-1 untuk mempercepat proses konvergensi selama pelatihan. Pra-pemrosesan dasar ini diterapkan pada kedua skenario data, baik pada citra asli maupun citra hasil *digital hair removal*. Oleh karena itu, tahap pra-pemrosesan dasar diterapkan secara konsisten pada kedua skenario tersebut. Tujuan dari tahapan ini adalah memastikan bahwa kedua model menerima distribusi data yang konsisten sehingga perbandingan performa menjadi adil.

Tahap pra-pemrosesan dasar meliputi proses resize citra menjadi 224×224 piksel dan normalisasi nilai piksel menggunakan parameter ImageNet. Pada skenario tanpa Digital Hair Removal, tahapan ini diterapkan langsung pada citra original. Sementara itu, pada skenario dengan Digital Hair Removal, proses penghilangan rambut dilakukan terlebih dahulu sebelum citra menjalani resize dan normalisasi.

3.3.5 *Digital Hair Removal*

Pada penelitian ini, *Digital Hair Removal* diterapkan sebagai perlakuan eksperimen untuk menghilangkan artefak rambut pada citra dermoskopi sebelum proses pelatihan model. Metode yang digunakan merupakan pendekatan morfologi klasik, yang diawali dengan konversi citra RGB ke grayscale, dilanjutkan dengan operasi *black-hat transform* menggunakan kernel berukuran 17x17 untuk menonjolkan struktur rambut yang tipis dan berwarna gelap. Hasilnya kemudian melalui proses *thresholding* untuk menghasilkan *mask* rambut, dan area yang terdeteksi direkonstruksi menggunakan metode *inpainting* Telea. Seluruh citra diproses secara *batch* dan disimpan sebagai dataset baru, sehingga penelitian ini menggunakan dua skenario data, yaitu citra asli dan citra setelah *digital hair removal*. Tahapan ini hanya diterapkan pada skenario kedua, yaitu skenario dengan Digital Hair Removal. Pada skenario pertama, citra original digunakan secara langsung tanpa proses penghilangan rambut.Ilustrasi rancangan proses *hair removal* dapat dilihat pada Gambar 3.3.



Gambar 3.4. Ilustrasi rancangan proses *digital hair removal*

3.3.6 *Split Data*

Dataset yang telah melalui tahap pra-pemrosesan dibagi menjadi data *training*, *validation*, dan *testing*. Pembagian ini dilakukan untuk memastikan bahwa model dapat dievaluasi secara objektif dan untuk mencegah terjadinya *overfitting*. Data *validation* digunakan untuk memantau proses pelatihan dan menerapkan *early stopping*, sedangkan data *testing* digunakan untuk evaluasi akhir performa model setelah proses pelatihan selesai. Augmentasi data dan penanganan *class imbalance* hanya diterapkan pada data *training* untuk menghindari *data leakage*. Mengingat distribusi kelas yang tidak seimbang antara benign dan malignant, penelitian ini menggunakan teknik *class weight* pada fungsi *loss* sehingga model tidak bias terhadap kelas mayoritas. Pendekatan ini dipilih agar distribusi asli dataset pada data *validation* dan *testing* tetap terjaga dan representatif terhadap kondisi data sebenarnya.

3.3.7 Pelatihan Model

Pada tahap ini dilakukan pelatihan model *deep learning* untuk melakukan klasifikasi citra dermoskopi ke dalam dua kategori, yaitu benign dan malignant. Penelitian ini menggunakan dua arsitektur *lightweight Convolutional Neural Network* (CNN), yaitu EfficientNet-B0 dan MobileNetV2. Kedua arsitektur tersebut dipilih karena memiliki efisiensi komputasi yang baik dengan jumlah parameter yang relatif lebih kecil dibandingkan arsitektur CNN lainnya. Proses pelatihan dirancang

menggunakan pendekatan *transfer learning* dengan memanfaatkan bobot awal yang telah dilatih pada dataset ImageNet. Bagian akhir model kemudian disesuaikan untuk tugas klasifikasi biner sehingga model dapat menghasilkan prediksi kelas benign dan malignant.

Pelatihan model dilakukan pada dua skenario data, yaitu menggunakan citra dermoskopi asli tanpa proses *digital hair removal* dan menggunakan citra yang telah melalui proses *digital hair removal*. Dengan demikian, diperoleh empat konfigurasi eksperimen yang akan dibandingkan performanya, yaitu EfficientNet-B0, MobileNetV2, EfficientNet-B0 dengan *digital hair removal*, dan MobileNetV2 dengan *digital hair removal*. Hasil dari pelatihan keempat model tersebut selanjutnya digunakan pada tahap evaluasi untuk menganalisis pengaruh *digital hair removal terhadap performa klasifikasi*.

3.3.8 Evaluasi Model

Evaluasi model dilakukan untuk mengukur kinerja model dalam melakukan klasifikasi citra dermoskopi ke dalam kategori benign dan malignant. Evaluasi ini dilakukan menggunakan *confusion matrix* serta beberapa metrik klasifikasi, yaitu *accuracy*, *precision*, *recall*, dan F1-*score*. Metrik-metrik tersebut digunakan untuk menilai kemampuan model dalam mengidentifikasi setiap kelas secara akurat serta untuk memahami keseimbangan antara prediksi yang benar dan kesalahan klasifikasi yang terjadi.

Selain metrik klasifikasi, penelitian ini juga mengevaluasi efisiensi komputasi dari masing-masing arsitektur model. Evaluasi efisiensi dilakukan dengan mengukur jumlah parameter model, serta waktu inferensi. Pengukuran ini bertujuan untuk mengetahui keseimbangan antara tingkat akurasi model dan efisiensi komputasi yang dimiliki oleh setiap arsitektur *lightweight* CNN yang digunakan. Hasil evaluasi dari masing-masing konfigurasi model kemudian dibandingkan untuk menganalisis pengaruh penerapan *digital hair removal* terhadap performa klasifikasi serta untuk mengidentifikasi model yang memberikan kinerja terbaik pada dataset citra dermoskopi yang digunakan dalam penelitian ini.

3.3.9 Analisis Hasil

Tahap analisis hasil dilakukan setelah proses evaluasi model untuk menginterpretasikan kinerja masing-masing konfigurasi model yang telah diuji. Analisis ini bertujuan untuk membandingkan performa model pada dua skenario data, yaitu tanpa *digital hair removal* dan dengan *digital hair remova*l, sehingga dapat diketahui pengaruh proses penghilangan artefak rambut terhadap hasil klasifikasi. Perbandingan dilakukan berdasarkan nilai metrik evaluasi yang diperoleh, yaitu *accuracy*, *precision*, *recall*, dan F1-*score*, serta aspek efisiensi komputasi seperti jumlah parameter model, dan waktu inferensi. Selain itu, analisis juga dilakukan dengan mengamati *confusion matrix* untuk mengidentifikasi pola kesalahan klasifikasi yang terjadi pada masing-masing model. Melalui tahap analisis ini, penelitian bertujuan untuk menentukan konfigurasi model yang memberikan performa terbaik serta memahami sejauh mana penerapan *digital hair removal* dapat meningkatkan kemampuan model dalam melakukan klasifikasi citra dermoskopi secara lebih akurat dan efisien.

3.3.10 Implementasi dalam Bentuk Website

Tahap ini bertujuan untuk mengimplementasikan hasil penelitian dalam bentuk prototipe website sederhana menggunakan *framework* Flask. Model terbaik yang diperoleh dari hasil evaluasi, baik dari arsitektur EfficientNet-B0 maupun MobileNetV2 pada skenario terbaik (dengan atau tanpa *digital hair removal*), akan diintegrasikan ke dalam aplikasi berbasis web. Aplikasi ini dirancang agar pengguna dapat mengunggah citra dermoskopi dan memperoleh hasil prediksi klasifikasi secara langsung dalam bentuk kategori benign atau malignant beserta nilai probabilitasnya. Implementasi ini dilakukan sebagai demonstrasi penerapan model hasil penelitian dalam lingkungan antarmuka pengguna yang interaktif, serta untuk memvisualisasikan alur inferensi model secara praktis.

BAB IV
HASIL DAN PEMBAHASAN

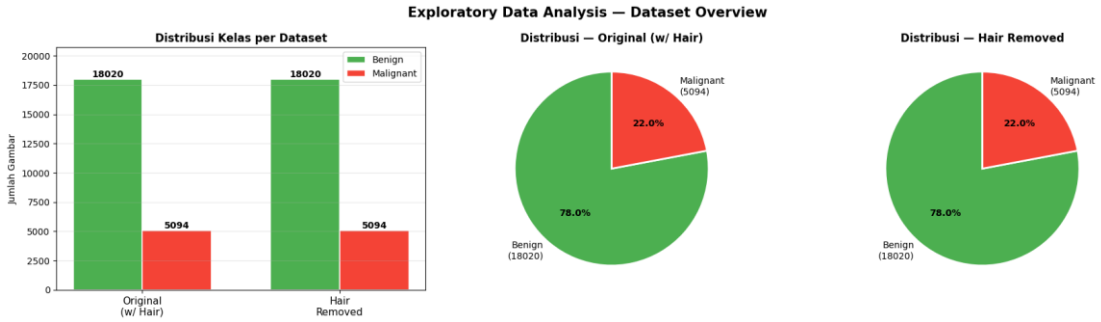
4.1 EKSPLORASI DATA

Tahap eksplorasi data dilakukan untuk memahami karakteristik dataset sebelum proses praproses dan pelatihan model. Pada penelitian ini, eksplorasi dilakukan terhadap dua kondisi citra, yaitu citra *original* dan citra hasil *Digital Hair Removal*. Analisis mencakup distribusi kelas, visualisasi sampel citra, dimensi gambar, intensitas piksel, serta pemeriksaan duplikasi data. Tahap ini bertujuan untuk memastikan kualitas dataset dan mengidentifikasi karakteristik data yang dapat memengaruhi kinerja model klasifikasi melanoma.

4.1.1 Distribusi Data

Analisis distribusi data dilakukan untuk mengetahui komposisi kelas pada dataset yang digunakan. Pada penelitian ini, dataset terdiri atas dua kondisi citra, yaitu *original* dan hasil *Digital Hair Removal*. Kedua dataset memiliki jumlah dan label data yang sama karena proses *Digital Hair Removal* hanya mengubah karakteristik visual citra tanpa mengubah jumlah maupun kelas data.

Distribusi kelas pada kedua dataset ditunjukkan pada Gambar 4.1. Masing-masing dataset terdiri atas 23.114 citra dermoskopi, dengan kelas benign sebanyak 18.020 citra (77,97%) dan kelas malignant sebanyak 5.094 citra (22,03%). Hal ini menunjukkan bahwa proses *Digital Hair Removal* tidak memengaruhi distribusi data.



Gambar 4.1. Distribusi kelas pada dataset

Berdasarkan distribusi tersebut, dataset memiliki kondisi *class imbalance*, karena kelas benign lebih dominan dibandingkan kelas malignant. Jumlah citra benign

sekitar 3,5 kali lebih banyak daripada malignant. Kondisi ini berpotensi menyebabkan model lebih cenderung mengenali kelas mayoritas. Oleh karena itu, penelitian ini menerapkan strategi penanganan ketidakseimbangan data menggunakan *WeightedRandomSampler* dan *class weight* pada fungsi *loss*. Rincian jumlah citra pada masing-masing dataset dan kelas disajikan pada Tabel 4.1.

Tabel 4.1. Distribusi kelas pada dataset

Dataset	Kelas	Jumlah Citra	Persentase
Original	Benign	18.020	77,97%
	Malignant	5.094	22,03%
	Total	**23.114**	**100,00%**
Hair Removed	Benign	18.020	77,97%
	Malignant	5.094	22,03%
	Total	**23.114**	**100,00%**

4.1.2 Visualisasi Sampel Data

Untuk memperoleh pemahaman yang lebih mendalam mengenai karakteristik visual dataset, dilakukan visualisasi sampel citra dari dataset *original* dan dataset hasil *Digital Hair Removal*. Visualisasi ini bertujuan untuk mengamati variasi bentuk, ukuran, warna, tekstur, serta keberadaan artefak rambut pada citra dermoskopi yang digunakan dalam penelitian. Selain itu, visualisasi sampel data juga dilakukan untuk mengevaluasi secara kualitatif pengaruh proses *Digital Hair Removal* terhadap tampilan lesi kulit sebelum digunakan dalam proses pelatihan model klasifikasi melanoma.

Visualisasi sampel citra ditampilkan pada Gambar 4.2, yang memperlihatkan perbandingan beberapa citra dermoskopi sebelum dan sesudah penerapan *Digital Hair Removal*. Pada setiap pasangan citra, gambar pada baris atas merupakan citra *original* yang masih mengandung artefak rambut, sedangkan gambar pada baris bawah merupakan citra hasil *Digital Hair Removal*. Penyajian secara berpasangan ini bertujuan untuk memudahkan pengamatan terhadap perubahan visual yang terjadi setelah proses penghilangan rambut.



Gambar 4.2. Perbandingan citra dermoskopi sebelum dan sesudah penerapan *digital hair removal*

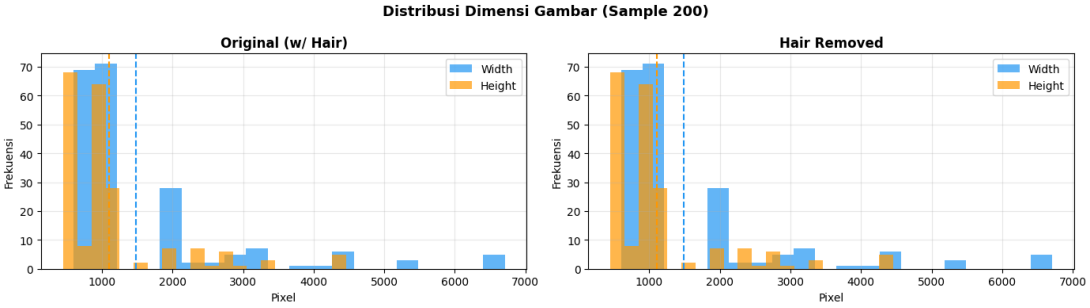
Berdasarkan visualisasi pada Gambar 4.2, dapat diamati bahwa proses *Digital Hair Removal* mampu mengurangi keberadaan artefak rambut yang menutupi area lesi pada sebagian besar citra. Rambut yang sebelumnya melintang di atas lesi berhasil dihilangkan melalui proses *inpainting* sehingga area lesi menjadi lebih jelas dan mudah diamati. Selain itu, struktur utama lesi seperti bentuk, batas, pola pigmentasi, dan distribusi warna secara umum masih dapat dipertahankan setelah proses *Digital Hair Removal* dilakukan.

Meskipun demikian, pada beberapa citra masih terlihat sisa artefak atau perubahan tekstur ringan pada area yang sebelumnya tertutupi rambut. Hal ini merupakan konsekuensi dari proses rekonstruksi piksel yang dilakukan oleh metode *inpainting*. Secara keseluruhan, hasil visualisasi menunjukkan bahwa metode *Digital Hair Removal* yang digunakan mampu mengurangi gangguan visual akibat rambut tanpa mengubah karakteristik utama lesi secara signifikan. Kondisi ini diharapkan dapat membantu model dalam mengekstraksi fitur yang lebih relevan selama proses klasifikasi melanoma.

4.1.3 Analisis Karakteristik Data

Analisis karakteristik data dilakukan untuk memperoleh pemahaman yang lebih mendalam mengenai atribut visual dataset yang dapat memengaruhi proses praproses dan pelatihan model. Pada penelitian ini, analisis karakteristik data difokuskan pada distribusi dimensi gambar dan distribusi intensitas piksel. Analisis

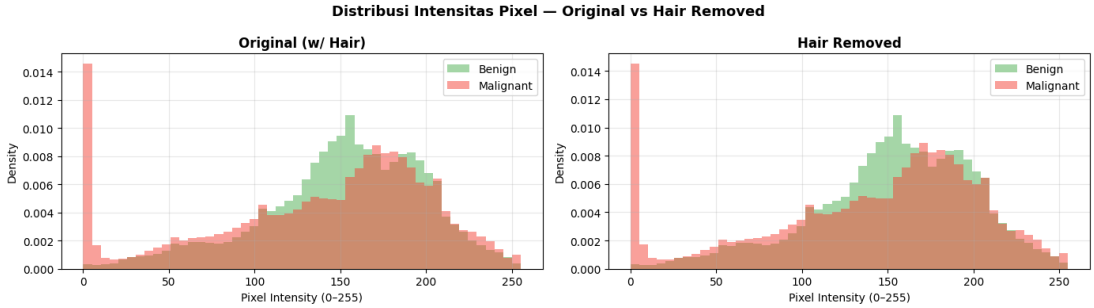
dimensi gambar bertujuan untuk mengetahui variasi ukuran citra yang digunakan, sedangkan analisis intensitas piksel dilakukan untuk memahami distribusi nilai piksel pada dataset *original* dan dataset hasil *Digital Hair Removal*. Hasil analisis ini menjadi dasar dalam menentukan strategi normalisasi dan penyesuaian ukuran citra sebelum digunakan sebagai masukan model klasifikasi. Distribusi dimensi gambar pada kedua dataset ditampilkan pada Gambar 4.3.



Gambar 4.3. Distribusi dimensi gambar pada dataset original dan *hair removed*

Berdasarkan Gambar 4.3, dapat diamati bahwa dimensi citra pada dataset memiliki variasi yang cukup beragam, baik pada dataset *original* maupun dataset hasil *Digital Hair Removal*. Meskipun demikian, pola distribusi pada kedua dataset terlihat hampir identik karena proses *Digital Hair Removal* tidak mengubah ukuran asli citra. Hasil analisis terhadap 200 sampel citra menunjukkan bahwa rata-rata lebar gambar pada kedua dataset adalah sekitar 1.486 piksel, sedangkan rata-rata tinggi gambar mencapai sekitar 1.106 piksel. Selain itu, sebagian besar citra terkonsentrasi pada rentang ukuran antara 500 hingga 2.000 piksel, meskipun terdapat beberapa citra dengan dimensi yang jauh lebih besar.

Keberagaman ukuran citra tersebut menunjukkan bahwa dataset tidak memiliki dimensi yang seragam. Oleh karena itu, diperlukan proses penyesuaian ukuran (*resizing*) pada tahap praproses agar seluruh citra memiliki ukuran input yang konsisten sesuai dengan kebutuhan arsitektur MobileNetV2 dan EfficientNet-B0. Pada penelitian ini, seluruh citra diubah menjadi ukuran 224 x 224 piksel sebelum digunakan dalam proses pelatihan model. Selain dimensi gambar, karakteristik dataset juga dianalisis melalui distribusi intensitas piksel yang ditampilkan pada Gambar 4.4.



Gambar 4.4. Distribusi intensitas piksel pada dataset original dan *hair removed*

Gambar 4.4 menunjukkan distribusi intensitas piksel pada kelas benign dan malignant untuk dataset *original* maupun dataset hasil *Digital Hair Removal*. Secara umum, pola distribusi intensitas pada kedua dataset memiliki bentuk yang relatif serupa dengan konsentrasi nilai piksel yang dominan berada pada rentang intensitas menengah hingga tinggi, yaitu sekitar 100 hingga 220. Hal ini menunjukkan bahwa sebagian besar area pada citra dermoskopi didominasi oleh warna kulit dan jaringan lesi dengan tingkat kecerahan menengah.

Perbandingan antara dataset *original* dan dataset hasil *Digital Hair Removal* menunjukkan adanya perubahan distribusi intensitas pada beberapa rentang nilai piksel. Perubahan tersebut terjadi akibat proses penghilangan rambut dan rekonstruksi area yang sebelumnya tertutupi artefak rambut melalui metode *inpainting*. Meskipun demikian, pola distribusi secara keseluruhan tetap dipertahankan, yang mengindikasikan bahwa proses *Digital Hair Removal* tidak menyebabkan perubahan karakteristik visual citra secara drastis. Dengan demikian, informasi penting yang berkaitan dengan lesi kulit masih dapat dipertahankan, sementara gangguan visual akibat keberadaan rambut dapat diminimalkan sebelum citra digunakan dalam proses klasifikasi melanoma.

4.1.4 Pengecekan Duplikasi Data

Pengecekan duplikasi data dilakukan untuk memastikan tidak terdapat citra identik yang dapat memengaruhi proses pelatihan maupun evaluasi model. Deteksi duplikasi dilakukan menggunakan metode *Message Digest Algorithm* 5 (MD5), di mana setiap file citra dikonversi menjadi nilai *hash* unik. File yang memiliki nilai hash yang sama dianggap sebagai duplikasi sempurna karena memiliki isi file yang identik. Pemeriksaan dilakukan terhadap seluruh 23.114 citra dermoskopi yang digunakan

dalam penelitian, yang terdiri atas 18.020 citra benign dan 5.094 citra malignant. Hasil pengecekan menunjukkan bahwa seluruh citra memiliki nilai *hash* yang unik sehingga tidak ditemukan adanya data duplikat pada dataset. Dengan demikian, dataset yang digunakan dapat dinyatakan memiliki integritas yang baik dan layak digunakan untuk proses pelatihan, validasi, serta pengujian model.

Kondisi ini juga mengurangi risiko terjadinya *data leakage*, yaitu kondisi ketika citra yang sama muncul pada lebih dari satu subset data sehingga dapat menyebabkan hasil evaluasi model menjadi terlalu optimistis dan tidak merepresentasikan kemampuan generalisasi model yang sebenarnya.

4.2 PRAPROSES DATA

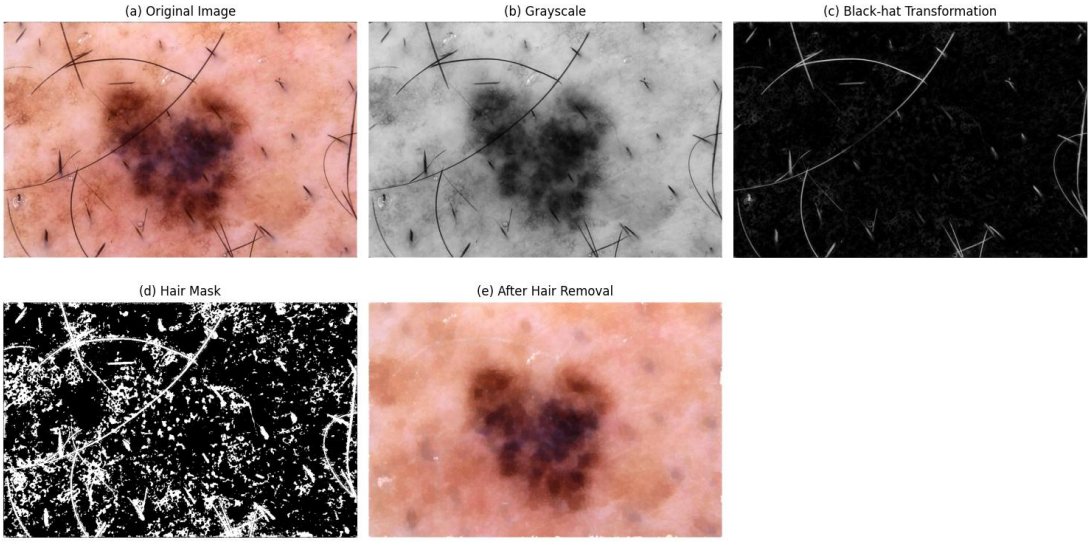
Praproses data merupakan tahapan yang dilakukan untuk mempersiapkan citra dermoskopi sebelum digunakan dalam proses pelatihan model klasifikasi melanoma. Tahap ini bertujuan untuk meningkatkan kualitas data, mengurangi gangguan visual yang dapat memengaruhi proses ekstraksi fitur, serta memastikan seluruh citra memiliki format yang sesuai dengan kebutuhan model. Pada penelitian ini, praproses data meliputi penerapan *Digital Hair Removal* untuk menghilangkan artefak rambut pada citra dermoskopi, pembagian dataset menjadi data pelatihan, validasi, dan pengujian, normalisasi citra untuk menyeragamkan representasi piksel, serta augmentasi data guna meningkatkan keragaman sampel pelatihan. Seluruh tahapan praproses dilakukan secara konsisten pada kedua skenario dataset sehingga perbedaan performa model yang diperoleh dapat dievaluasi berdasarkan pengaruh penerapan *Digital Hair Removal*.

4.2.1 *Digital Hair Removal*

Digital Hair Removal dilakukan sebagai salah satu tahap praproses untuk mengurangi artefak rambut pada citra dermoskopi. Artefak rambut dapat menutupi sebagian area lesi sehingga berpotensi mengganggu proses ekstraksi fitur oleh model klasifikasi. Pada penelitian ini, metode *Digital Hair Removal* diterapkan pada seluruh citra *original* untuk menghasilkan dataset baru yang disebut sebagai dataset *hair removed*. Dataset hasil *Digital Hair Removal* tetap memiliki struktur kelas yang sama

dengan dataset *original*, yaitu benign dan malignant, sehingga perbandingan performa model dapat dilakukan secara konsisten.

Metode *digital hair removal* yang digunakan dalam penelitian ini merupakan pendekatan morfologi klasik yang terdiri atas beberapa tahapan utama. Pertama, citra masukan dikonversi dari format warna BGR ke *grayscale*. Konversi ini bertujuan untuk menyederhanakan informasi citra sehingga struktur rambut yang umumnya tampak sebagai garis gelap dapat lebih mudah dideteksi. Kedua, dilakukan operasi *black-hat transform* menggunakan kernel berbentuk persegi panjang berukuran 17×17. Operasi *black-hat* digunakan untuk menonjolkan objek gelap berukuran kecil pada latar yang lebih terang, sehingga sesuai untuk mendeteksi rambut tipis pada citra dermoskopi. Ketiga, hasil *black-hat* diproses menggunakan *threshold* dengan nilai ambang 10 untuk membentuk mask rambut. Area yang terdeteksi sebagai rambut pada mask tersebut kemudian direkonstruksi menggunakan metode *inpainting* Telea dengan radius 1 piksel. Proses *inpainting* bertujuan untuk mengganti area rambut dengan estimasi piksel di sekitarnya agar tampilan citra menjadi lebih bersih. Alur proses *Digital Hair Removal* yang diterapkan pada penelitian ini dapat dilihat pada Gambar 4.5.



Gambar 4.5. Alur proses *Digital Hair Remov*al menggunakan *black-hat transformation* dan *inpainting*

Proses *Digital Hair Removal* dilakukan secara batch pada seluruh citra dalam dataset *original*. Pada kelas benign, proses dilakukan terhadap 18.020 citra, sedangkan

pada kelas malignant dilakukan terhadap 5.094 citra. Hasil dari proses ini disimpan kembali ke dalam direktori baru dengan struktur kelas yang sama seperti dataset *original*. Dengan demikian, diperoleh dua skenario dataset yang digunakan dalam penelitian, yaitu dataset *original* tanpa *Digital Hair Removal* dan dataset hasil *Digital Hair Removal*.

Visualisasi hasil penerapan *Digital Hair Removal* dapat dilihat pada Gambar 4.6. Gambar tersebut menunjukkan beberapa contoh citra dermoskopi sebelum dan sesudah proses penghilangan rambut. Pada citra *original*, terlihat bahwa beberapa rambut melintang di atas area lesi. Setelah proses *Digital Hair Removal* dilakukan, sebagian besar rambut yang tipis, gelap, dan berjarak berhasil dikurangi sehingga area lesi tampak lebih bersih.



Gambar 4.6. Perbandingan citra sebelum dan sesudah penerapan *Digital Hair Removal*

Berdasarkan pengamatan visual terhadap hasil *digital hair removal*, metode ini cukup efektif untuk menghilangkan rambut yang tipis, berwarna gelap, dan memiliki jarak antar rambut yang tidak terlalu rapat. Pada citra dengan karakteristik tersebut, operasi *black-hat* mampu menonjolkan struktur rambut dengan cukup baik sehingga *mask* rambut dapat terbentuk dan proses *inpainting* dapat mengganti area rambut dengan piksel di sekitarnya. Hasilnya, sebagian garis rambut yang sebelumnya menutupi area lesi menjadi berkurang, sehingga citra tampak lebih bersih dibandingkan citra *original*.

Namun, efektivitas metode ini menurun pada citra yang memiliki rambut tebal, padat, atau saling bertumpuk. Pada kondisi tersebut, rambut tidak selalu terdeteksi

secara sempurna oleh operasi *black-hat* dan thresholding. Beberapa bagian rambut yang tebal masih tampak setelah proses inpainting, terutama jika rambut menutupi area lesi dalam ukuran yang cukup besar. Hal ini disebabkan oleh parameter yang digunakan, yaitu kernel 17×17 dan *threshold* 10, lebih sesuai untuk mendeteksi rambut tipis berbentuk garis kecil. Selain itu, radius *inpainting* sebesar 1 piksel relatif kecil sehingga proses rekonstruksi hanya bekerja pada area yang sangat dekat dengan piksel sekitar. Akibatnya, pada rambut yang tebal atau padat, hasil rekonstruksi belum mampu mengembalikan tampilan kulit dan lesi secara optimal.

Selain keterbatasan dalam menghapus rambut tebal, hasil *digital hair removal* juga menunjukkan adanya penurunan kualitas visual pada beberapa citra. Citra hasil inpainting pada area tertentu tampak sedikit lebih halus atau kurang tajam dibandingkan citra *original*. Kondisi ini terjadi karena proses *inpainting* bekerja dengan mengganti piksel pada area *mask* berdasarkan informasi piksel di sekitarnya. Pada area yang memiliki tekstur lesi kompleks, pola warna tidak homogen, atau batas lesi yang tidak beraturan, proses rekonstruksi dapat mengubah sebagian detail visual citra. Dengan demikian, meskipun *digital hair removal* dapat mengurangi gangguan rambut, proses ini juga berpotensi menghilangkan atau mengubah sebagian informasi visual yang penting bagi model klasifikasi.

Pada penelitian ini juga dilakukan pengujian tambahan dengan menerapkan proses *digital hair removal* lebih dari satu kali pada citra yang sama. Berdasarkan pengamatan, proses *digital hair removal* kedua tidak memberikan perubahan visual yang signifikan dibandingkan hasil digital hair removal pertama. Hal ini terjadi karena metode yang digunakan bersifat deterministik dan sangat bergantung pada mask rambut yang dihasilkan dari operasi *black-hat* dan *thresholding*. Setelah proses pertama, rambut yang berhasil terdeteksi telah diganti melalui *inpainting*. Ketika citra hasil *digital hair removal* diproses ulang menggunakan parameter yang sama, struktur rambut yang masih tersisa umumnya tetap tidak terdeteksi oleh *mask* karena karakteristiknya tidak sesuai dengan parameter deteksi yang digunakan. Dengan kata lain, apabila rambut tebal atau padat tidak berhasil dideteksi pada proses pertama, maka pengulangan proses dengan parameter yang sama cenderung tidak menghasilkan penghapusan tambahan yang berarti.

Temuan ini menunjukkan bahwa *digital hair removal* berbasis morfologi klasik memiliki efektivitas yang terbatas. Metode ini dapat bekerja dengan baik pada rambut tipis dan terpisah, tetapi kurang optimal untuk rambut tebal, padat, atau yang menutupi area lesi secara luas. Oleh karena itu, hasil *digital hair removal* pada penelitian ini tidak diposisikan sebagai metode penghilangan rambut yang sempurna, melainkan sebagai perlakuan pra-pemrosesan untuk mengevaluasi sejauh mana pengurangan artefak rambut dapat memengaruhi performa arsitektur *lightweight* CNN. Keterbatasan tersebut juga menjadi salah satu faktor yang perlu diperhatikan dalam analisis hasil model, terutama apabila performa model pada citra hasil *digital hair removal* tidak selalu lebih baik dibandingkan citra *original*.

4.2.2 Pembagian Dataset

Setelah dataset original dan dataset hasil *digital hair removal* terbentuk, tahap selanjutnya adalah membagi masing-masing dataset ke dalam tiga subset, yaitu data latih, data validasi, dan data uji. Pembagian dataset dilakukan menggunakan metode *stratified split* untuk memastikan proporsi kelas benign dan malignant tetap terjaga pada setiap subset. Pendekatan ini dipilih karena dataset yang digunakan memiliki distribusi kelas yang tidak seimbang, sehingga setiap subset perlu memiliki representasi kelas yang sama dengan distribusi data secara keseluruhan.

Proses pembagian dilakukan menggunakan fungsi *train_test_split* dengan parameter *stratify* berdasarkan label kelas dan *random_state* sebesar 42 untuk menjamin reproduksibilitas hasil eksperimen. Dataset dibagi dengan rasio 70% untuk data latih, 15% untuk data validasi, dan 15% untuk data uji. Pada tahap pertama, sebesar 15% data dipisahkan sebagai data uji. Selanjutnya, sisa data dibagi kembali untuk memperoleh data validasi sebesar 15% dari total dataset, sehingga diperoleh komposisi akhir sesuai dengan rasio yang telah ditentukan.

Hasil pembagian dataset ditunjukkan pada Tabel 4.2. Pada dataset original diperoleh 16.179 citra untuk data latih, 3.467 citra untuk data validasi, dan 3.468 citra untuk data uji. Komposisi yang sama juga diperoleh pada dataset hasil *Digital Hair Removal* karena kedua dataset memiliki jumlah dan label citra yang identik. Distribusi kelas benign dan malignant pada setiap subset tetap mempertahankan proporsi awal

dataset, sehingga karakteristik data dapat terjaga selama proses pelatihan maupun evaluasi model.

Tabel 4.2 menunjukkan bahwa kelas benign tetap mendominasi seluruh subset dengan proporsi sekitar 78%, sedangkan kelas malignant memiliki proporsi sekitar 22%. Konsistensi distribusi tersebut menunjukkan bahwa metode *stratified split* berhasil mempertahankan representasi masing-masing kelas pada setiap subset. Data latih digunakan untuk proses pembelajaran model, data validasi digunakan untuk memantau performa model selama pelatihan dan mendukung penerapan *early stopping*, sedangkan data uji digunakan untuk mengevaluasi performa akhir model pada data yang belum pernah dilihat sebelumnya.

Tabel 4.2. Distribusi Data *train-validation-test split*

Dataset	Subset	Benign	Malignant	Total	Persentase
Original	Train	12.613	3.566	16.179	70,0%
	Validation	2.703	764	3.467	15,0%
	Test	2.704	764	3.468	15,0%
	Total				**100,0%**
Hair Removed	Train	12.613	3.566	16.179	70,0%
	Validation	2.703	764	3.467	15,0%
	Test	2.704	764	3.468	15,0%
	Total				**100,0%**

4.2.3 Normalisasi Citra

Sebelum digunakan dalam proses pelatihan model, seluruh citra terlebih dahulu melalui tahap normalisasi untuk menyeragamkan ukuran dan distribusi nilai piksel. Pada penelitian ini, citra yang memiliki ukuran asli yang beragam diubah ukurannya (*resize*) menjadi 224 × 224 piksel agar sesuai dengan ukuran input yang dibutuhkan oleh arsitektur MobileNetV2 dan EfficientNet-B0. Proses penyeragaman ukuran ini bertujuan untuk memastikan seluruh citra memiliki dimensi yang konsisten sehingga dapat diproses secara optimal oleh model.

Setelah proses *resize*, citra dikonversi menjadi tensor menggunakan fungsi ToTensor(), yang secara otomatis mengubah rentang nilai piksel dari [0, 255] menjadi [0, 1]. Selanjutnya, dilakukan normalisasi menggunakan nilai rata-rata (*mean*) [0.485, 0.456, 0.406] dan standar deviasi (*standard deviation*) [0.229, 0.224, 0.225] pada

masing-masing kanal warna RGB. Nilai tersebut merupakan parameter normalisasi yang digunakan pada dataset ImageNet.

Penggunaan parameter normalisasi ImageNet dilakukan karena kedua arsitektur yang digunakan dalam penelitian ini memanfaatkan bobot *pretrained* hasil pelatihan pada dataset ImageNet. Dengan menyesuaikan distribusi nilai piksel terhadap distribusi data saat proses *pretraining*, proses *transfer learning* dapat berjalan lebih efektif dan stabil. Tahap normalisasi ini diterapkan secara konsisten pada seluruh data latih, validasi, dan pengujian baik pada dataset original maupun dataset hasil *digital hair removal*.

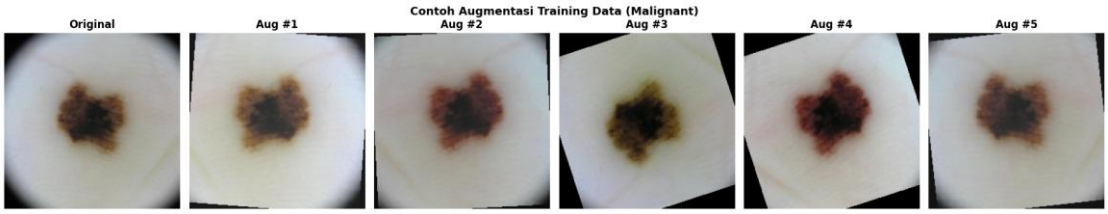
4.2.4 Augmentasi Data

Augmentasi data diterapkan hanya pada data latih (*training set*) untuk meningkatkan variasi sampel pelatihan secara artifisial dan mengurangi risiko *overfitting*. Proses augmentasi dilakukan secara *on-the-fly* menggunakan *transforms.Compose()* dari *library* PyTorch, sehingga setiap citra yang digunakan selama pelatihan dapat mengalami transformasi acak yang berbeda pada setiap epoch tanpa mengubah data asli yang tersimpan. Sementara itu, data validasi dan data uji tidak dikenai augmentasi, melainkan hanya melalui proses *resize* dan normalisasi agar evaluasi model dilakukan pada kondisi data yang konsisten.

Teknik augmentasi yang digunakan meliputi *Random Crop*, *Random Horizontal Flip*, *Random Vertical Flip*, *Random Rotation*, *Color Jitter*, dan *Random Grayscale*. Kombinasi transformasi tersebut bertujuan untuk mensimulasikan variasi posisi, orientasi, pencahayaan, kontras, serta karakteristik warna yang mungkin ditemui pada citra dermoskopi. Dengan demikian, model diharapkan mampu mempelajari fitur lesi yang lebih robust dan memiliki kemampuan generalisasi yang lebih baik terhadap data yang belum pernah dilihat sebelumnya. Rincian teknik augmentasi yang diterapkan pada data latih disajikan pada Tabel 4.3, sedangkan contoh hasil augmentasi dapat dilihat pada Gambar 4.7.

Tabel 4.3. Teknik augmentasi data pada training set

No	Teknik Augmentasi	Parameter	Tujuan
1.	*Random Horizontal Flip*	p = 0,5	Menambah variasi orientasi horizontal lesi
2.	*Random Vertical Flip*	p = 0,3	Menambah variasi orientasi vertikal lesi
3.	*Random Rotation*	±20°	Mensimulasikan variasi sudut pengambilan citra
4.	*Color Jitter*	*brightness*=0,2; *contrast*=0,2; *saturation*=0,15, *hue*=0,05	Mensimulasikan variasi pencahayaan dan warna
5.	*Random Grayscale*	p = 0,05	Mengurangi ketergantungan model terhadap informasi warna tertentu



Gambar 4.7. Contoh hasil augmentasi pada citra melanoma

Berdasarkan Gambar 4.7, terlihat bahwa proses augmentasi menghasilkan variasi orientasi, posisi, dan karakteristik warna pada citra tanpa mengubah struktur utama lesi. Variasi tersebut memungkinkan model memperoleh sampel pelatihan yang lebih beragam sehingga dapat meningkatkan kemampuan generalisasi dan mengurangi kecenderungan *overfitting* selama proses pelatihan.

4.3 PERANCANGAN ARSITEKTUR MODEL

Pada penelitian ini, dua arsitektur *Convolutional Neural Network* (CNN) ringan (*lightweight CNN*) digunakan sebagai model utama, yaitu MobileNetV2 dan

EfficientNet-B0. Kedua arsitektur dipilih karena memiliki jumlah parameter yang relatif kecil dibandingkan model CNN konvensional, sehingga mampu memberikan efisiensi komputasi yang lebih baik tanpa mengorbankan performa klasifikasi secara signifikan. Selain itu, kedua model telah banyak digunakan dalam berbagai penelitian klasifikasi citra medis dan terbukti memiliki kemampuan yang baik dalam mengekstraksi fitur visual.

Kedua model memanfaatkan bobot *pretrained* dari dataset ImageNet melalui pendekatan *transfer learning*. Pada tahap awal pelatihan, seluruh lapisan backbone dibekukan (*frozen*) dan hanya classifier yang dilatih untuk menyesuaikan model terhadap tugas klasifikasi melanoma. Selanjutnya, dilakukan proses *fine-tuning* dengan membuka kembali lapisan backbone sehingga model dapat mempelajari karakteristik spesifik citra dermoskopi secara lebih optimal. Untuk menyesuaikan model dengan tugas klasifikasi biner melanoma, classifier bawaan masing-masing arsitektur diganti dengan *classifier* kustom yang terdiri dari lapisan *fully connected*, fungsi aktivasi ReLU, *batch normalization*, dan *dropout*. Modifikasi ini bertujuan untuk meningkatkan kemampuan klasifikasi sekaligus mengurangi risiko *overfitting* selama proses pelatihan.

4.3.1 Arsitektur EfficientNet-B0

EfficientNet-B0 digunakan sebagai *backbone* dengan bobot *pretrained* ImageNet1K_V1. Arsitektur ini dipilih karena mampu menghasilkan performa yang baik dengan jumlah parameter yang relatif kecil melalui penerapan konsep *compound scaling*, yaitu pendekatan yang menyeimbangkan kedalaman (*depth*), lebar (*width*), dan resolusi (*resolution*) jaringan secara efisien. Pada penelitian ini, pendekatan *transfer learning* diterapkan dengan memanfaatkan bobot hasil pelatihan pada dataset ImageNet untuk mempercepat proses konvergensi dan meningkatkan kemampuan ekstraksi fitur.

Lapisan *classifier* bawaan EfficientNet-B0 dihapus dan diganti dengan *classifier* kustom yang dirancang khusus untuk klasifikasi biner melanoma. *Backbone* EfficientNet-B0 terdiri atas beberapa *Mobile Inverted Bottleneck Convolution* (MBConv) *blocks* yang menggabungkan *depthwise separable convolution* dan mekanisme *Squeeze-and-Excitation* (SE) untuk meningkatkan efisiensi komputasi

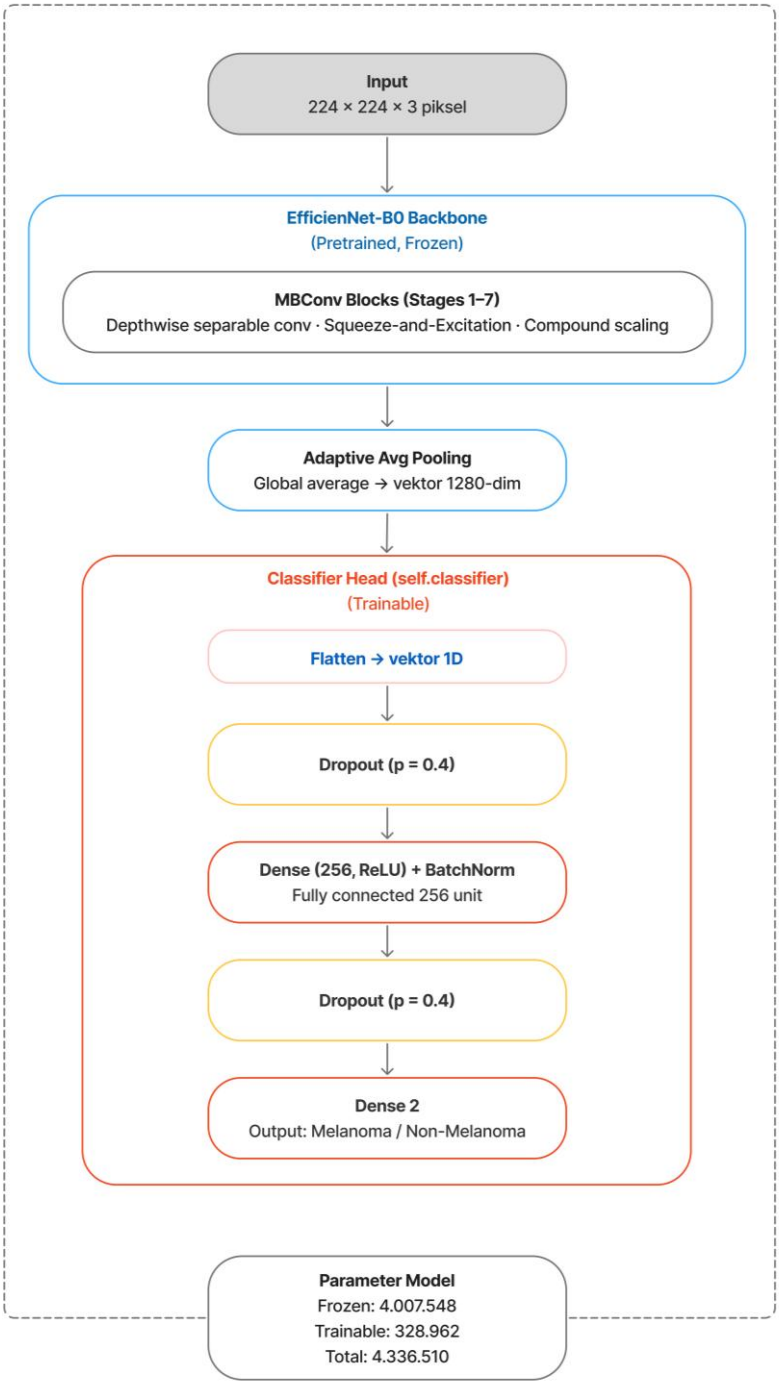
serta kemampuan representasi fitur. Hasil akhir *backbone* menghasilkan representasi fitur berupa vektor berdimensi 1280 setelah melewati proses *adaptive average pooling*. Struktur arsitektur EfficientNet-B0 yang digunakan pada penelitian ini ditunjukkan pada Tabel 4.4.

Tabel 4.4. Struktur Arsitektur EfficientNet-B0

No	Lapisan	Keterangan
1	*Input*	224 × 224 × 3 piksel
2	*MBConv Blocks (Stages 1–7)*	*Depthwise separable convolution* dan *Squeeze-and-Excitation*
3	*Adaptive Average Pooling*	Menghasilkan vektor fitur 1280 dimensi
4	*Flatten*	Meratakan tensor menjadi vektor 1D
5	*Dropout (p = 0,4)*	Mengurangi risiko *overfitting*
6	*Dense (256, ReLU) + BatchNorm1d*	*Fully connected 256 unit*
7	*Dropout (p = 0,3)*	Mengurangi risiko *overfitting*
8	*Dense (2)*	Output 2 kelas: Benign/Malignant

Tabel 4.4. menunjukkan bahwa model menerima input citra berukuran 224 × 224 × 3 piksel yang kemudian diproses oleh rangkaian MBConv blocks sebagai backbone utama. Hasil ekstraksi fitur dari backbone diringkas melalui adaptive average pooling sehingga menghasilkan vektor fitur berdimensi 1280. Selanjutnya, vektor fitur tersebut diteruskan ke classifier kustom yang terdiri atas lapisan dropout, fully connected 256 unit dengan aktivasi ReLU dan Batch Normalization, serta lapisan output dengan dua neuron untuk membedakan kelas benign dan malignant.

Visualisasi arsitektur lengkap EfficientNet-B0 yang digunakan pada penelitian ini ditunjukkan pada Gambar 4.8.



Gambar 4.8. Arsitektur Model EfficientNet-B0

Berdasarkan hasil perhitungan parameter model, EfficientNet-B0 memiliki total 4.336.510 parameter, yang terdiri atas 328.962 parameter *trainable* pada *classifier* dan 4.007.548 parameter *frozen* pada *backbone* hasil *pretraining* ImageNet.

4.3.2 Arsitektur MobileNetV2

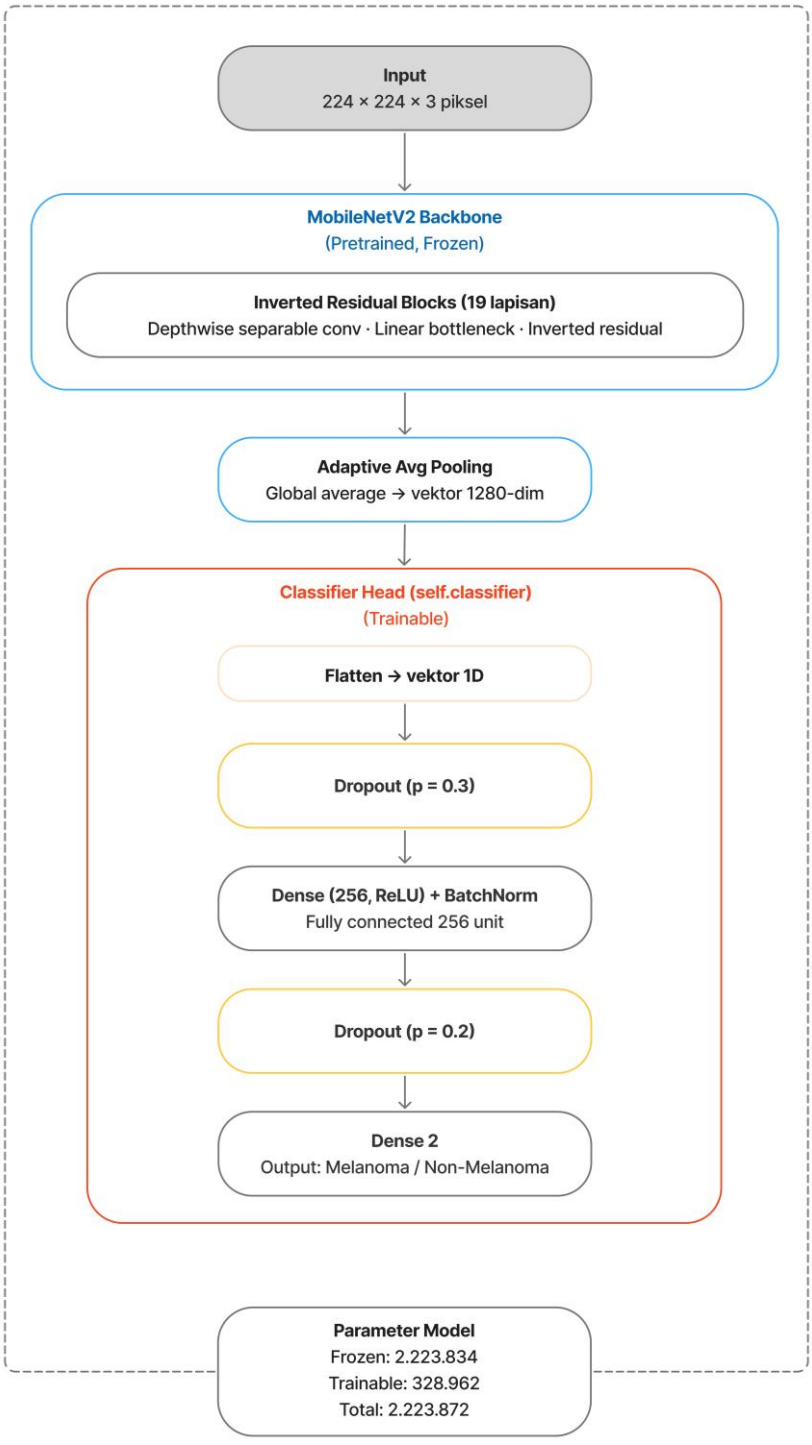
MobileNetV2 digunakan sebagai *backbone* dengan bobot *pretrained* ImageNet1K_V1. Sama seperti EfficientNet-B0, lapisan *classifier* bawaan dihapus dan diganti dengan *classifier* kustom yang dirancang untuk tugas klasifikasi biner melanoma. Arsitektur MobileNetV2 dipilih karena memiliki efisiensi komputasi yang tinggi dengan jumlah parameter yang relatif kecil, sehingga termasuk dalam kategori *lightweight CNN* yang sesuai untuk implementasi pada perangkat dengan sumber daya terbatas.

Backbone MobileNetV2 menggunakan struktur *inverted residual blocks* dengan *linear bottleneck* yang terdiri atas beberapa blok konvolusi berurutan. Keunggulan utama arsitektur ini terletak pada penggunaan *depthwise separable convolution*, yaitu teknik yang memisahkan proses konvolusi spasial dan konvolusi kanal sehingga mampu mengurangi jumlah parameter serta kebutuhan komputasi dibandingkan konvolusi standar. Melalui pendekatan tersebut, MobileNetV2 dapat mempertahankan performa klasifikasi yang baik dengan kompleksitas model yang lebih rendah. Hasil akhir backbone menghasilkan representasi fitur berupa vektor berdimensi 1280 setelah melewati proses *adaptive average pooling*. *Classifier* kustom yang digunakan terdiri atas lapisan *Dropout*, *Fully Connected Layer*, fungsi aktivasi ReLU, *Batch Normalization*, dan lapisan *output* dengan dua neuron yang merepresentasikan kelas benign dan malignant. Struktur arsitektur MobileNetV2 yang digunakan pada penelitian ini ditunjukkan pada Tabel 4.5.

Tabel 4.5. Struktur Arsitektur MobileNetV2

No	Lapisan	Keterangan
1	*Input*	224 × 224 × 3 piksel
2	*Inverted Residual Blocks*	*Depthwise separable convolution, linear bottleneck, dan shortcut connection*
3	*Adaptive Average Pooling*	Menghasilkan vektor fitur 1280 dimensi
4	*Flatten*	Meratakan tensor menjadi vektor 1D
5	*Dropout (p = 0,3)*	Mengurangi risiko *overfitting*
6	*Dense (256, ReLU) + BatchNorm1d*	*Fully connected 256 unit*
7	*Dropout (p = 0,2)*	Mengurangi risiko *overfitting*
8	*Dense (2)*	Output 2 kelas: Benign/Malignant

Visualisasi arsitektur lengkap MobileNetV2 yang digunakan pada penelitian ini ditunjukkan pada Gambar 4.9.



Gambar 4.9. Arsitektur Model MobileNetV2

Berdasarkan hasil perhitungan parameter model, MobileNetV2 memiliki total 2.552.834 parameter, yang terdiri atas 328.962 parameter trainable pada classifier dan 2.223.872 parameter *frozen* pada *backbone* hasil *pretraining* ImageNet. Jumlah parameter yang lebih sedikit dibandingkan EfficientNet-B0 menunjukkan bahwa MobileNetV2 memiliki kompleksitas model yang lebih rendah, sehingga berpotensi memberikan waktu inferensi yang lebih cepat dan kebutuhan komputasi yang lebih ringan.

4.4 PENGEMBANGAN MODEL

Pengembangan model dilakukan menggunakan dua arsitektur *lightweight Convolutional Neural Network* (CNN), yaitu EfficientNet-B0 dan MobileNetV2. Masing-masing arsitektur dilatih menggunakan dua skenario dataset yang berbeda, yaitu dataset *original* dan dataset hasil *digital hair removal*. Dengan demikian, terdapat empat model yang dikembangkan dalam penelitian ini, yaitu EfficientNet-B0 *Original*, EfficientNet-B0 *Hair Removed*, MobileNetV2 *Original*, dan MobileNetV2 *Hair Removed*. Seluruh model dikembangkan menggunakan pendekatan *transfer learning* dengan memanfaatkan bobot *pretrained* dari ImageNet. Pada tahap awal, hanya *classifier* yang dilatih sementara *backbone* dibekukan (*frozen*). Selanjutnya, seluruh lapisan model dibuka kembali untuk proses *fine-tuning* sehingga model dapat mempelajari karakteristik citra dermoskopi secara lebih optimal. Setelah proses pelatihan selesai, model terbaik dipilih berdasarkan performa pada data validasi untuk digunakan pada tahap evaluasi.

4.4.1 Konfigurasi Pelatihan

Seluruh eksperimen pelatihan menggunakan konfigurasi yang sama pada kedua arsitektur untuk memastikan perbandingan dilakukan secara adil. Konfigurasi pelatihan yang digunakan ditunjukkan pada Tabel 4.6.

Tabel 4.6. Konfigurasi pelatihan

No	Parameter	Nilai
1	*Optimizer*	AdamW
2	*Loss Function*	*Cross Entropy Loss*
3	*Batch Size*	128

No	Parameter	Nilai
4	*Epoch Maksimum*	30
5	*Learning Rate Phase 1 (Frozen Backbone)*	0.001
6	*Learning Rate Phase 2 (Full Fine-Tuning)*	0.0001
7	*Early Stopping Patience*	7
8	*WeightedRandomSampler*	Aktif
9	*Mixed Precision (AMP)*	Aktif
10	*Monitor*	*Validation Loss*

Pelatihan dilakukan menggunakan *optimizer* AdamW dan fungsi *loss Cross Entropy Loss* dengan ukuran *batch* sebesar 128 citra. Seluruh model dilatih hingga maksimum 30 epoch dengan mekanisme *early stopping* menggunakan nilai *patience* sebesar 7 berdasarkan *validation loss*.

Strategi pelatihan dilakukan dalam dua fase. Pada fase pertama (epoch 1–10), seluruh lapisan *backbone* dibekukan (frozen) sehingga hanya *classifier* yang dilatih menggunakan *learning rate* sebesar 0,001. Pendekatan ini bertujuan agar *classifier* dapat terlebih dahulu beradaptasi dengan karakteristik dataset melanoma tanpa mengubah representasi fitur yang telah dipelajari dari ImageNet. Pada fase kedua (epoch 11–30), seluruh lapisan *backbone* dibuka kembali (*unfreeze*) dan dilatih bersama *classifier* menggunakan *learning rate* yang lebih kecil, yaitu 0,0001. Strategi ini memungkinkan model melakukan penyesuaian fitur secara lebih spesifik terhadap citra dermoskopi sekaligus menjaga stabilitas proses pelatihan.

Selain itu, pelatihan dilakukan menggunakan teknik *Mixed Precision Training* (AMP) untuk mempercepat komputasi dan mengurangi penggunaan memori GPU. Untuk mengatasi ketidakseimbangan kelas antara benign dan malignant, diterapkan *WeightedRandomSampler* pada data latih sehingga setiap kelas memiliki peluang yang lebih seimbang untuk dipilih selama proses pelatihan.

4.4.2 Pelatihan Model

Pelatihan model dilakukan pada empat skenario eksperimen yang terdiri atas dua arsitektur CNN, yaitu EfficientNet-B0 dan MobileNetV2, dengan masing-masing dua kondisi dataset, yaitu dataset *original* dan dataset hasil *digital hair removal*. Pelatihan model dirancang menggunakan strategi dua fase, yaitu fase pertama dengan pembekuan *backbone* dan pelatihan *classifier head* pada epoch 1–10, kemudian

dilanjutkan dengan fase *fine-tuning* penuh pada epoch 11–30. Namun, apabila *validation loss* tidak mengalami perbaikan selama sejumlah epoch tertentu, proses pelatihan dihentikan lebih awal menggunakan mekanisme *early stopping*. Hasil pelatihan keempat model ditunjukkan pada Tabel 4.7.

Tabel 4.7. Hasil eksperimen pelatihan

Model	**Epoch Terbaik**	***Train Accuracy***	***Validation Accuracy***	***Train Loss***	***Validation Loss***	**Waktu (menit)**
EfficientNet-B0 Original	18	88,91%	84,28%	0,1668	0,3265	97,3
EfficientNet-B0 Hair Removed	25	91,17%	84,66%	0,1348	0,3464	122,3
MobileNetV2 Original	22	91,40%	87,28%	0,1352	0,3332	145,2
MobileNetV2 Hair Removed	1	72,22%	61,55%	0,4007	0,5275	43,4

Berdasarkan hasil pelatihan pada Tabel 4.7, model MobileNetV2 Original menghasilkan *validation accuracy* tertinggi sebesar 87,28% dengan *validation loss* sebesar 0,3332 pada epoch ke-22. Sementara itu, EfficientNet-B0 Original mencapai *validation accuracy* sebesar 84,28% dengan *validation loss* terendah sebesar 0,3265 pada epoch ke-18. Pada dataset hasil *digital hair removal*, EfficientNet-B0 *Hair Removed* memperoleh *validation accuracy* sebesar 84,66% dengan *validation loss* 0,3464 pada epoch ke-25.

Berbeda dengan tiga model lainnya, MobileNetV2 *Hair Removed* menunjukkan performa pelatihan yang jauh lebih rendah. Model ini hanya mencapai *validation accuracy* sebesar 61,55% dengan *validation loss* sebesar 0,5275 pada epoch pertama dan mengalami penghentian pelatihan lebih awal (*early stopping*) pada epoch ke-8 karena tidak terjadi perbaikan performa selama tujuh epoch berturut-turut. Kondisi ini mengindikasikan bahwa kombinasi antara arsitektur MobileNetV2 dan dataset hasil *digital hair removal* mengalami kesulitan dalam mempelajari representasi fitur yang optimal.

Secara umum, proses *fine-tuning* pada fase kedua memberikan peningkatan performa yang signifikan pada tiga model utama, yaitu EfficientNet-B0 *Original*, EfficientNet-B0 *Hair Removed*, dan MobileNetV2 *Original*. Hal ini terlihat dari

penurunan *validation loss* serta peningkatan *validation accuracy* setelah seluruh lapisan *backbone* dibuka kembali untuk dilatih. Temuan awal ini menunjukkan bahwa pengaruh *digital hair removal* terhadap proses pembelajaran model tidak selalu bersifat positif dan dapat berbeda pada setiap arsitektur. Analisis lebih lanjut mengenai dampak *digital hair removal* terhadap performa klasifikasi akan dibahas pada tahap evaluasi model.

4.5 EVALUASI MODEL

Tahap evaluasi model dilakukan menggunakan data uji (*test set*) yang tidak pernah digunakan selama proses pelatihan maupun validasi. Evaluasi bertujuan untuk mengukur kemampuan generalisasi model dalam melakukan klasifikasi melanoma pada citra dermoskopi. Metrik yang digunakan meliputi *accuracy, precision, recall (sensitivity), specificity, F1-score*, AUC-ROC, serta waktu inferensi (*inference time*). Selain itu, *confusion matrix* digunakan untuk memberikan gambaran mengenai distribusi prediksi benar dan salah pada masing-masing kelas.

4.5.1 Evaluasi EfficientNet-B0

Hasil evaluasi arsitektur EfficientNet-B0 pada data uji ditunjukkan pada Tabel 4.8. Evaluasi dilakukan terhadap dua model, yaitu EfficientNet-B0 *Original* dan EfficientNet-B0 *Hair Removed*, menggunakan data uji sebanyak 3.468 citra yang terdiri atas 2.704 citra benign dan 764 citra malignant.

Tabel 4.8. Hasil Evaluasi EfficientNet-B0 pada Data Uji

Metrik	***Original***	***Hair Removed***
Accuracy	83,28%	**84,08%**
Precision	0,5768	**0,5928**
Recall	**0,9045**	0,8861
Specificity	0,8125	**0,8280**
F1-Score	0,7044	**0,7104**
AUC-ROC	**0,9438**	0,9432
Inference Time (ms/img)	**19,996**	20,417

Classification report untuk masing-masing model ditunjukkan pada Tabel 4.9 dan Tabel 4.10.

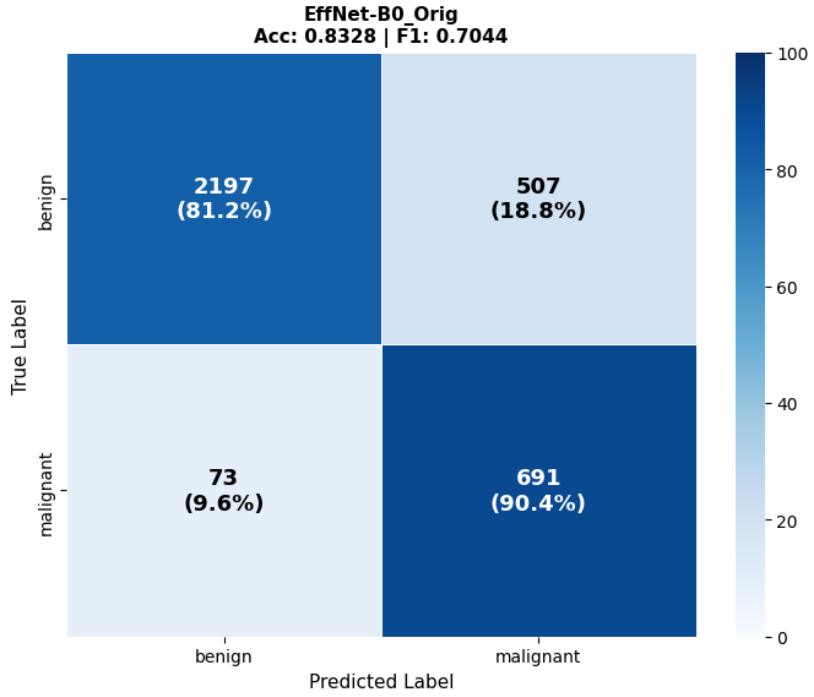
Tabel 4.9. *Classification Report* EfficientNet-B0 *Original*

Kelas	*Precision*	*Recall*	*F1-Score*	*Support*
Benign	0,9678	0,8125	0,8834	2.704
Malignant	0,5768	0,9045	0,7044	764
Macro Average	0,7723	0,8585	0,7939	3.468

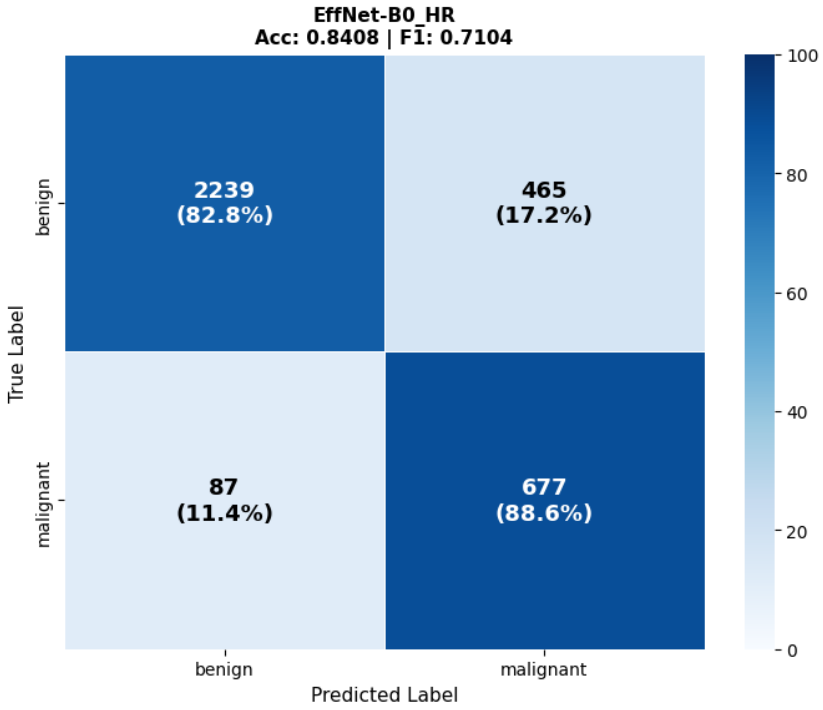
Tabel 4.10. *Classification Report* EfficientNet-B0 *Hair Removed*

Kelas	*Precision*	*Recall*	*F1-Score*	*Support*
Benign	0,9626	0,8280	0,8903	2.704
Malignant	0,5928	0,8861	0,7104	764
Macro Average	0,7777	0,8571	0,8003	3.468

Confusion matrix EfficientNet-B0 *Original* dan EfficientNet-B0 *Hair Removed* ditunjukkan pada Gambar 4.10 dan Gambar 4.11.



Gambar 4.10. *Confusion Matrix* EfficientNet-B0 *Original*



Gambar 4.11. *Confusion Matrix* EfficientNet-B0 *Hair Removed*

Berdasarkan hasil evaluasi pada Tabel 4.8, kedua model EfficientNet-B0 menunjukkan performa klasifikasi yang baik dengan nilai AUC-ROC di atas 0,94. Model EfficientNet-B0 *Original* memperoleh *accuracy* sebesar 83,28%, sedangkan EfficientNet-B0 *Hair Removed* memperoleh *accuracy* sebesar 84,08%. Hasil tersebut menunjukkan bahwa penerapan *digital hair removal* memberikan peningkatan *accuracy* sebesar 0,80%.

Berdasarkan *confusion matrix*, EfficientNet-B0 *Original* berhasil mengklasifikasikan 2.888 dari 3.468 citra dengan benar, terdiri atas 2.197 citra benign dan 691 citra malignant. Sementara itu, EfficientNet-B0 *Hair Removed* berhasil mengklasifikasikan 2.916 citra dengan benar, terdiri atas 2.239 citra benign dan 677 citra malignant. Jumlah *false positive* menurun dari 507 citra menjadi 465 citra setelah penerapan *digital hair removal*, yang menunjukkan peningkatan kemampuan model dalam mengenali citra benign.

Meskipun *recall* untuk kelas malignant mengalami sedikit penurunan dari 0,9045 menjadi 0,8861, peningkatan *precision, specificity, accuracy*, dan F1-*score* menunjukkan bahwa *digital hair removal* memberikan dampak positif terhadap kinerja EfficientNet-B0 secara keseluruhan. Temuan ini mengindikasikan bahwa

penghilangan artefak rambut mampu membantu EfficientNet-B0 dalam mempelajari representasi fitur yang lebih relevan sehingga menghasilkan prediksi yang lebih seimbang antara kedua kelas.

4.5.2 Evaluasi MobileNetV2

Hasil evaluasi arsitektur MobileNetV2 pada data uji ditunjukkan pada Tabel 4.11. Evaluasi dilakukan terhadap dua model, yaitu MobileNetV2 *Original* dan MobileNetV2 *Hair Removed*, menggunakan data uji sebanyak 3.468 citra yang terdiri atas 2.704 citra benign dan 764 citra malignant.

Tabel 4.11. Hasil Evaluasi MobileNetV2 pada Data Uji

Metrik	***Original***	***Hair Removed***
Accuracy	**87,02%**	59,98%
Precision	**0,6524**	0,3472
Recall	0,8796	**0,9280**
Specificity	**0,8676**	0,5070
F1-Score	**0,7492**	0,5053
AUC-ROC	**0,9433**	0,8533
Inference Time (ms/img)	**26,698**	32,567

Classification report untuk masing-masing model ditunjukkan pada Tabel 4.12 dan Tabel 4.13.

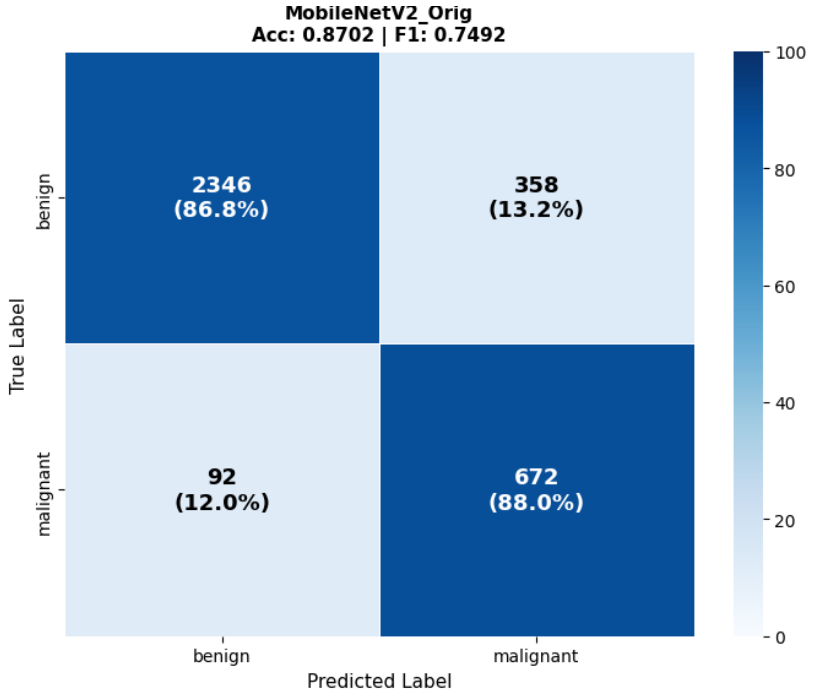
Tabel 4.12. *Classification Report* MobileNetV2 *Original*

Kelas	***Precision***	***Recall***	***F1-Score***	***Support***
Benign	0,9623	0,8676	0,9125	2.704
Malignant	0,6524	0,8796	0,7492	764
Macro Average	0,8074	0,8736	0,8309	3.468

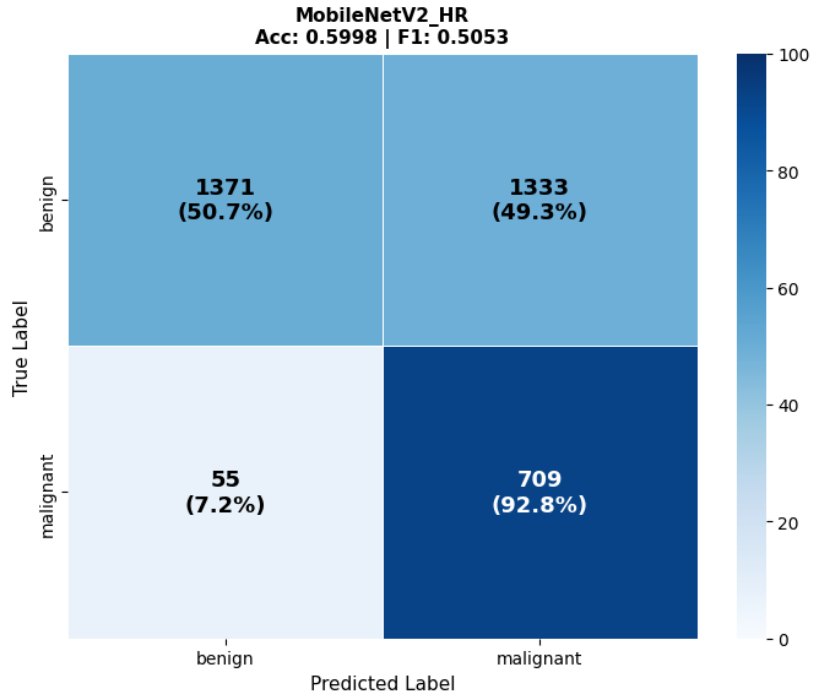
Tabel 4.13. *Classification Report* MobileNetV2 *Hair Removed*

Kelas	***Precision***	***Recall***	***F1-Score***	***Support***
Benign	0,9614	0,5070	0,6638	2.704
Malignant	0,3472	0,9280	0,5053	764
Macro Average	0,6543	0,7175	0,5846	3.468

Confusion matrix MobileNetV2 *Original* dan MobileNetV2 *Hair Removed* ditunjukkan pada Gambar 4.12 dan Gambar 4.13.



Gambar 4.12. *Confusion Matrix* MobileNetV2 *Original*



Gambar 4.13. *Confusion Matrix* MobileNetV2 *Hair Removed*

Berdasarkan hasil evaluasi pada Tabel 4.11, model MobileNetV2 *Original* menunjukkan performa klasifikasi yang baik dengan *accuracy* sebesar 87,02%, F1-*score* sebesar 0,7492, dan AUC-ROC sebesar 0,9433. Namun, setelah penerapan

digital hair removal, performa model mengalami penurunan yang cukup signifikan. *Accuracy* turun menjadi 59,98%, F1-*score* menurun menjadi 0,5053, dan AUC-ROC berkurang menjadi 0,8533.

Berdasarkan *confusion matrix*, MobileNetV2 *Original* berhasil mengklasifikasikan 3.018 dari 3.468 citra dengan benar, terdiri atas 2.346 citra benign dan 672 citra malignant. Sementara itu, MobileNetV2 *Hair Removed* hanya berhasil mengklasifikasikan 2.080 citra dengan benar, terdiri atas 1.371 citra benign dan 709 citra malignant. Jumlah *false positive* meningkat secara drastis dari 358 citra menjadi 1.333 citra setelah penerapan *digital hair removal*. Peningkatan *false positive* ini menyebabkan banyak citra benign salah diklasifikasikan sebagai malignant.

Meskipun *recall* untuk kelas malignant meningkat dari 0,8796 menjadi 0,9280, peningkatan tersebut tidak diikuti oleh peningkatan metrik lainnya. Sebaliknya, *precision, specificity, accurac*y, F1-*score*, dan AUC-ROC mengalami penurunan yang cukup besar. Hal ini menunjukkan bahwa model menjadi lebih sensitif dalam mendeteksi melanoma, tetapi kehilangan kemampuan untuk membedakan citra benign dan malignant secara seimbang. Temuan ini mengindikasikan bahwa penerapan *digital hair removal* justru memberikan dampak negatif terhadap kinerja MobileNetV2, yang kemungkinan disebabkan oleh hilangnya informasi visual penting selama proses penghilangan rambut sehingga fitur yang dipelajari model menjadi kurang representatif.

4.5.3 Perbandingan Efisiensi Komputasi

Perbandingan efisiensi komputasi dilakukan untuk mengevaluasi kinerja keempat model dari sisi kebutuhan sumber daya dan kecepatan inferensi. Evaluasi ini meliputi jumlah parameter, waktu inferensi per citra (*inference time*), dan *throughput*. Jumlah parameter diperoleh dari total parameter yang dimiliki setiap model setelah penambahan *classifier head*. Waktu inferensi diukur pada perangkat GPU NVIDIA Tesla T4 menggunakan data uji, sedangkan *throughput* dihitung berdasarkan jumlah citra yang dapat diproses per detik. Hasil perbandingan efisiensi komputasi ditunjukkan pada Tabel 4.14.

Tabel 4.14. Jumlah Parameter dan Efisiensi Komputasi

Model	**Jumlah Parameter**	***Inference Time* (ms/img)**	***Throughput* (img/s)**
EfficientNet-B0 *Original*	4.336.510	26,698	37,46
EfficientNet-B0 *Hair Removed*	4.336.510	32,567	30,71
MobileNetV2 *Original*	2.552.834	19,996	50,01
MobileNetV2 *Hair Removed*	2.552.834	20,417	48,98

Berdasarkan Tabel 4.14, MobileNetV2 memiliki jumlah parameter yang lebih sedikit dibandingkan EfficientNet-B0. Total parameter MobileNetV2 berjumlah 2.552.834, sedangkan EfficientNet-B0 memiliki 4.336.510 parameter. Dengan demikian, MobileNetV2 memiliki sekitar 1,78 juta parameter lebih sedikit atau sekitar 41,1% lebih ringan dibandingkan EfficientNet-B0. Kondisi ini sesuai dengan tujuan perancangan MobileNetV2 sebagai arsitektur ringan (*lightweight CNN*) yang dioptimalkan untuk perangkat dengan keterbatasan sumber daya komputasi melalui penggunaan *depthwise separable convolution* dan *inverted residual block*.

Meskipun memiliki jumlah parameter yang lebih besar, EfficientNet-B0 menunjukkan performa inferensi yang lebih cepat dibandingkan MobileNetV2. EfficientNet-B0 Original mencatat waktu inferensi rata-rata sebesar 19,996 ms per citra, sedangkan MobileNetV2 Original membutuhkan 26,698 ms per citra. Hasil serupa juga terlihat pada dataset hasil *digital hair removal*, di mana EfficientNet-B0 *Hair Removed* membutuhkan 20,417 ms per citra, sementara MobileNetV2 *Hair Removed* memerlukan 32,567 ms per citra. Perbedaan ini menunjukkan bahwa jumlah parameter yang lebih sedikit tidak selalu menghasilkan waktu inferensi yang lebih cepat, karena efisiensi eksekusi juga dipengaruhi oleh struktur arsitektur dan optimasi perangkat keras yang digunakan.

Dari sisi *throughput*, EfficientNet-B0 mampu memproses sekitar 50 citra per detik, sedangkan MobileNetV2 hanya mampu memproses sekitar 37 citra per detik pada dataset original dan 31 citra per detik pada dataset hasil *digital hair removal*. Hasil ini menunjukkan bahwa EfficientNet-B0 memiliki kemampuan pemrosesan yang lebih tinggi pada GPU Tesla T4. Selain itu, penerapan *digital hair removal* tidak memberikan pengaruh yang signifikan terhadap jumlah parameter model karena proses tersebut hanya mengubah citra masukan tanpa mengubah struktur arsitektur.

Perbedaan waktu inferensi dan *throughput* yang muncul setelah penerapan *digital hair removal* relatif kecil pada EfficientNet-B0, namun lebih terlihat pada MobileNetV2.

Secara keseluruhan, MobileNetV2 lebih unggul dari sisi ukuran model karena memiliki jumlah parameter yang lebih sedikit. Namun, EfficientNet-B0 menunjukkan efisiensi inferensi yang lebih baik dengan waktu prediksi yang lebih cepat dan *throughput* yang lebih tinggi. Temuan ini menunjukkan bahwa pemilihan model tidak hanya ditentukan oleh jumlah parameter, tetapi juga oleh kemampuan arsitektur dalam memanfaatkan sumber daya komputasi secara efektif. Oleh karena itu, penentuan model terbaik perlu mempertimbangkan keseimbangan antara efisiensi komputasi dan performa klasifikasi yang dicapai oleh masing-masing model.

4.5.4 Perbandingan Keseluruhan Kinerja Model

Perbandingan keseluruhan dilakukan untuk mengevaluasi performa klasifikasi dan efisiensi komputasi dari seluruh model yang dikembangkan pada penelitian ini. Perbandingan mencakup metrik *accuracy, precision, recall*, F1-*score*, AUC-ROC, jumlah parameter, waktu inferensi per citra, dan *throughput*. Hasil perbandingan keseluruhan keempat model ditunjukkan pada Tabel 4.15.

Tabel 4.15. Perbandingan Keseluruhan Kinerja Model

Metrik	**MobileNetV2 *Original***	**MobileNetV2 *Hair Removed***	**EfficientNet-B0 *Original***	**EfficientNet-B0 *Hair Removed***
Accuracy	**87,02%**	59,98%	83,28%	84,08%
Precision	**0,6524**	0,3472	0,5768	0,5928
Recall	0,8796	**0,9280**	0,9045	0,8861
F1-Score	**0,7492**	0,5053	0,7044	0,7104
AUC-ROC	0,9433	0,8533	**0,9438**	0,9432
Jumlah Parameter	**2.552.834**	2.552.834	4.336.510	4.336.510
Inference Time	26,698 ms	32,567 ms	**19,996 ms**	20,417 ms
Throughput	37,46 img/s	30,71 img/s	**50,01 img/s**	48,98 img/s

Berdasarkan Tabel 4.15, MobileNetV2 Original menghasilkan performa klasifikasi terbaik secara keseluruhan dengan *accuracy* sebesar 87,02%, *precision* sebesar 0,6524, dan F1-*score* sebesar 0,7492. Nilai tersebut merupakan yang tertinggi di antara seluruh model yang diuji. Selain itu, MobileNetV2 *Original* juga memiliki

jumlah parameter paling sedikit, yaitu 2.552.834 parameter, sehingga menunjukkan efisiensi model yang baik dari sisi ukuran arsitektur.

Pada arsitektur EfficientNet-B0, penerapan *digital hair removal* memberikan peningkatan performa klasifikasi. *Accuracy* meningkat dari 83,28% menjadi 84,08%, *precision* meningkat dari 0,5768 menjadi 0,5928, *specificity* meningkat dari 81,25% menjadi 82,80%, dan F1-*score* meningkat dari 0,7044 menjadi 0,7104. Hasil ini menunjukkan bahwa penghilangan artefak rambut mampu membantu EfficientNet-B0 dalam membangun representasi fitur yang lebih baik pada citra dermoskopi.

Sebaliknya, hasil yang berbeda ditemukan pada arsitektur MobileNetV2. Penerapan *digital hair removal* menyebabkan penurunan performa yang cukup signifikan. *Accuracy* turun dari 87,02% menjadi 59,98%, *precision* menurun dari 0,6524 menjadi 0,3472, dan F1-*score* turun dari 0,7492 menjadi 0,5053. Meskipun *recall* meningkat dari 0,8796 menjadi 0,9280, peningkatan tersebut diikuti oleh peningkatan jumlah *false positive* yang sangat besar sehingga menyebabkan penurunan kemampuan model dalam membedakan kelas benign dan malignant secara seimbang.

Dari sisi efisiensi komputasi, EfficientNet-B0 menunjukkan waktu inferensi yang lebih cepat dibandingkan MobileNetV2 meskipun memiliki jumlah parameter yang lebih besar. EfficientNet-B0 *Original* mencatat waktu inferensi sebesar 19,996 ms per citra dengan *throughput* 50,01 citra per detik, sedangkan MobileNetV2 *Original* membutuhkan 26,698 ms per citra dengan *throughput* 37,46 citra per detik. Temuan ini menunjukkan bahwa jumlah parameter yang lebih sedikit tidak selalu menghasilkan proses inferensi yang lebih cepat karena efisiensi komputasi juga dipengaruhi oleh karakteristik arsitektur dan optimasi perangkat keras.

Secara keseluruhan, MobileNetV2 *Original* merupakan model dengan performa klasifikasi terbaik berdasarkan *accuracy* dan F1-*score*, sedangkan EfficientNet-B0 *Original* menghasilkan nilai AUC-ROC tertinggi sebesar 0,9438. Selain itu, EfficientNet-B0 juga menunjukkan efisiensi inferensi yang lebih baik dibandingkan MobileNetV2. Perbedaan respons kedua arsitektur terhadap penerapan *digital hair removal* menunjukkan bahwa pengaruh teknik pra-pemrosesan tersebut tidak bersifat universal dan sangat bergantung pada karakteristik arsitektur yang digunakan. Oleh karena itu, diperlukan analisis lebih lanjut mengenai dampak

penerapan *digital hair removal* terhadap masing-masing model yang akan dibahas pada subbab berikutnya.

4.6 ANALISIS DAMPAK PENERAPAN *DIGITAL HAIR REMOVAL*

Analisis dampak *Digital Hair Remova*l (DHR) dilakukan untuk mengetahui pengaruh proses penghilangan artefak rambut terhadap kinerja model klasifikasi melanoma pada dua arsitektur *lightweight* CNN, yaitu EfficientNet-B0 dan MobileNetV2. Analisis dilakukan dengan membandingkan hasil evaluasi model yang dilatih menggunakan dataset *original* dengan model yang dilatih menggunakan dataset hasil *digital hair removal*. Nilai dampak dihitung berdasarkan selisih (delta) antara metrik pada dataset hasil DHR dan dataset original, sehingga nilai positif menunjukkan peningkatan performa, sedangkan nilai negatif menunjukkan penurunan performa. Hasil analisis dampak *digital hair removal* terhadap masing-masing metrik evaluasi ditunjukkan pada Tabel 4.16.

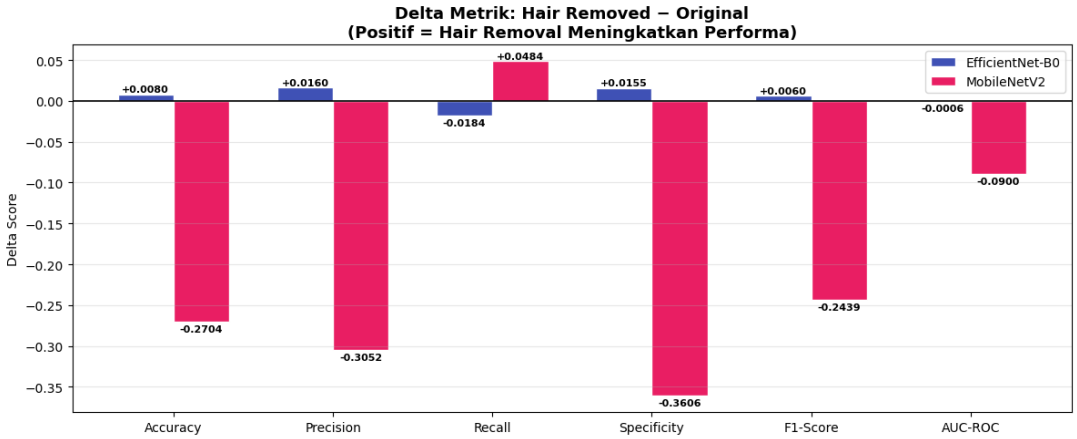
Tabel 4.16. Dampak *Digital Hair Removal* terhadap Kinerja Model

Metrik	**EfficientNet-B0 Δ**	**MobileNetV2 Δ**
Accuracy	+0,0080	-0,2704
Precision	+0,0160	-0,3052
Recall	-0,0184	+0,0484
Specificity	+0,0155	-0,3606
F1-Score	+0,0060	-0,2439
AUC-ROC	-0,0006	-0,0900

Keterangan:

$$\Delta = Hair\ Removed - Original$$

Visualisasi dampak *digital hair removal* terhadap setiap metrik evaluasi ditunjukkan pada Gambar 4.14.



Gambar 4.14. Dampak *Digital Hair Removal* terhadap Metrik Klasifikasi

Berdasarkan Tabel 4.16 dan Gambar 4.14, terlihat bahwa *digital hair removal* memberikan dampak yang berbeda pada masing-masing arsitektur. Pada EfficientNet-B0, sebagian besar metrik mengalami peningkatan setelah penerapan *digital hair removal*. *Accuracy* meningkat sebesar 0,0080, *precision* meningkat sebesar 0,0160, *specificity* meningkat sebesar 0,0155, dan F1-*score* meningkat sebesar 0,0060. Sementara itu, *recall* mengalami sedikit penurunan sebesar 0,0184 dan AUC-ROC turun sebesar 0,0006. Namun, penurunan tersebut relatif sangat kecil dibandingkan peningkatan yang diperoleh pada metrik lainnya. Hasil ini menunjukkan bahwa penghilangan artefak rambut membantu EfficientNet-B0 memperoleh representasi fitur yang lebih baik sehingga mampu meningkatkan kemampuan klasifikasi secara keseluruhan.

Sebaliknya, hasil yang berbeda ditemukan pada MobileNetV2. Penerapan *digital hair removal* menyebabkan penurunan performa yang cukup signifikan pada hampir seluruh metrik utama. *Accuracy* mengalami penurunan sebesar 0,2704, *precision* turun sebesar 0,3052, *specificity* turun sebesar 0,3606, F1-score turun sebesar 0,2439, dan AUC-ROC turun sebesar 0,0900. Meskipun *recall* meningkat sebesar 0,0484, peningkatan tersebut tidak diikuti oleh peningkatan metrik lainnya. Kondisi ini menunjukkan bahwa model cenderung menghasilkan lebih banyak prediksi positif sehingga jumlah *false positive* meningkat secara signifikan. Akibatnya, kemampuan model dalam membedakan kelas benign dan malignant menjadi menurun.

Perbedaan respons kedua arsitektur terhadap *digital hair removal* menunjukkan bahwa efektivitas teknik pra-pemrosesan sangat dipengaruhi oleh

karakteristik model yang digunakan. EfficientNet-B0 memanfaatkan kombinasi MBConv block, *depthwise separable convolution*, dan mekanisme *Squeeze-and-Excitation* yang memungkinkan model mempertahankan informasi penting pada area lesi meskipun citra mengalami perubahan akibat proses penghilangan rambut. Sebaliknya, MobileNetV2 yang memiliki jumlah parameter lebih sedikit dan struktur yang lebih ringan tampak lebih sensitif terhadap perubahan tekstur dan detail visual yang muncul setelah proses *digital hair removal*.

Temuan ini sejalan dengan hasil observasi visual pada tahap pra-pemrosesan. Berdasarkan perbandingan citra sebelum dan sesudah *digital hair removal*, metode yang digunakan terbukti cukup efektif untuk menghilangkan rambut yang tipis, gelap, dan berjarak. Namun, pada citra yang memiliki rambut tebal, padat, atau saling bertumpuk, sebagian rambut masih terlihat setelah proses penghilangan rambut dilakukan. Selain itu, proses *inpainting* yang digunakan untuk merekonstruksi area yang tertutup rambut terkadang menyebabkan detail tekstur lesi menjadi sedikit lebih halus dan kurang tajam dibandingkan citra *original*.

Selama penelitian juga dilakukan percobaan dengan menerapkan proses *digital hair removal* sebanyak dua kali secara berurutan menggunakan parameter yang sama. Namun, hasil yang diperoleh tidak menunjukkan perubahan visual yang signifikan dibandingkan proses *Digital Hair Removal* satu kali. Hal ini terjadi karena metode *black-hat transformation* dan *thresholding* bergantung pada mask rambut yang berhasil dideteksi. Setelah proses pertama selesai, rambut yang terdeteksi telah digantikan melalui proses *inpainting*, sedangkan sisa rambut yang tidak terdeteksi pada tahap pertama cenderung tetap tidak terdeteksi apabila parameter yang digunakan tidak berubah. Oleh karena itu, pengulangan proses *digital hair removal* dengan konfigurasi yang sama tidak selalu menghasilkan penghilangan rambut tambahan.

Berdasarkan keseluruhan hasil penelitian, dapat disimpulkan bahwa *Digital Hair Removal* tidak selalu memberikan peningkatan performa klasifikasi melanoma. Pada EfficientNet-B0, *digital hair removal* memberikan dampak positif dengan meningkatkan sebagian besar metrik evaluasi. Sebaliknya, pada MobileNetV2, *digital hair removal* justru menyebabkan penurunan performa yang cukup besar. Temuan ini menunjukkan bahwa keberhasilan *digital hair removal* tidak hanya ditentukan oleh kemampuan menghilangkan artefak rambut, tetapi juga oleh kemampuan arsitektur

CNN dalam mempertahankan informasi visual penting pada area lesi setelah proses pra-pemrosesan dilakukan.

4.7 IMPLEMENTASI PROTOTIPE APLIKASI WEB

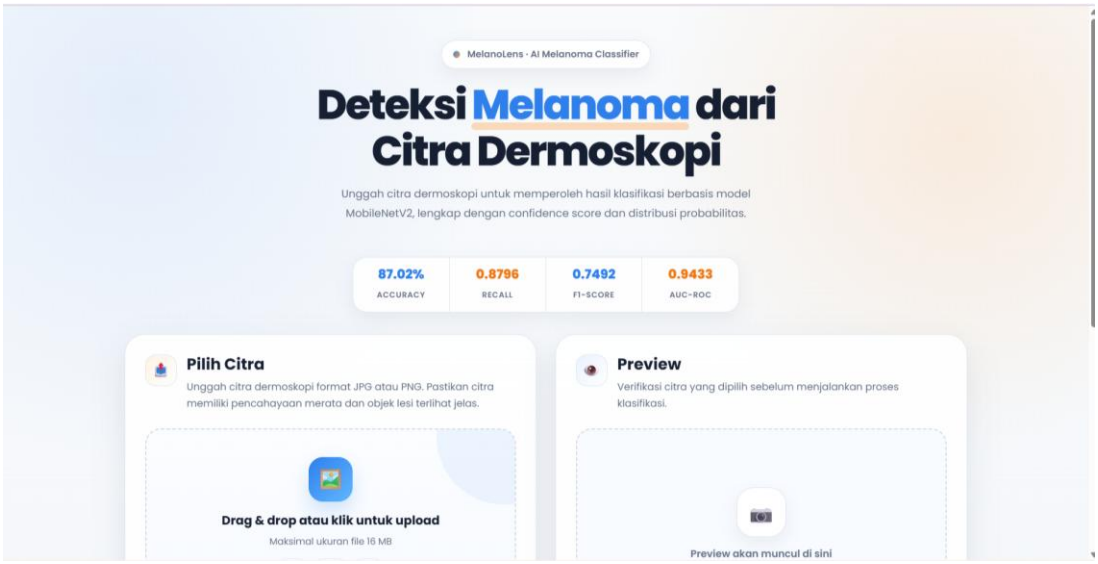
Prototipe aplikasi web dikembangkan sebagai implementasi dari model terbaik yang diperoleh pada penelitian ini. Berdasarkan hasil evaluasi, model MobileNetV2 *Original* digunakan sebagai model utama karena menghasilkan performa klasifikasi terbaik dengan *accuracy* sebesar 87,02%, *recall* sebesar 0,8796, F1-*score* sebesar 0,7492, dan AUC-ROC sebesar 0,9433. Aplikasi ini diberi nama MelanoLens dan dikembangkan menggunakan *framework* Flask sebagai *backend* serta antarmuka web berbasis HTML, CSS, dan JavaScript.

Aplikasi MelanoLens menerima input berupa citra dermoskopi dalam format JPG, JPEG, atau PNG dengan ukuran maksimal 16 MB. Setelah citra diunggah, sistem menampilkan *preview* gambar agar pengguna dapat memastikan citra yang dipilih sudah sesuai sebelum proses klasifikasi dilakukan. Selanjutnya, citra diproses melalui tahapan *preprocessing* yang sama dengan *pipeline* pengujian model, yaitu konversi citra ke format RGB, *resize* ke ukuran 224 × 224 piksel, konversi ke tensor, dan normalisasi menggunakan *mean* [0,485; 0,456; 0,406] serta standar deviasi [0,229; 0,224; 0,225]. *Pipeline* ini digunakan untuk menjaga konsistensi distribusi input antara tahap pelatihan dan tahap inferensi.

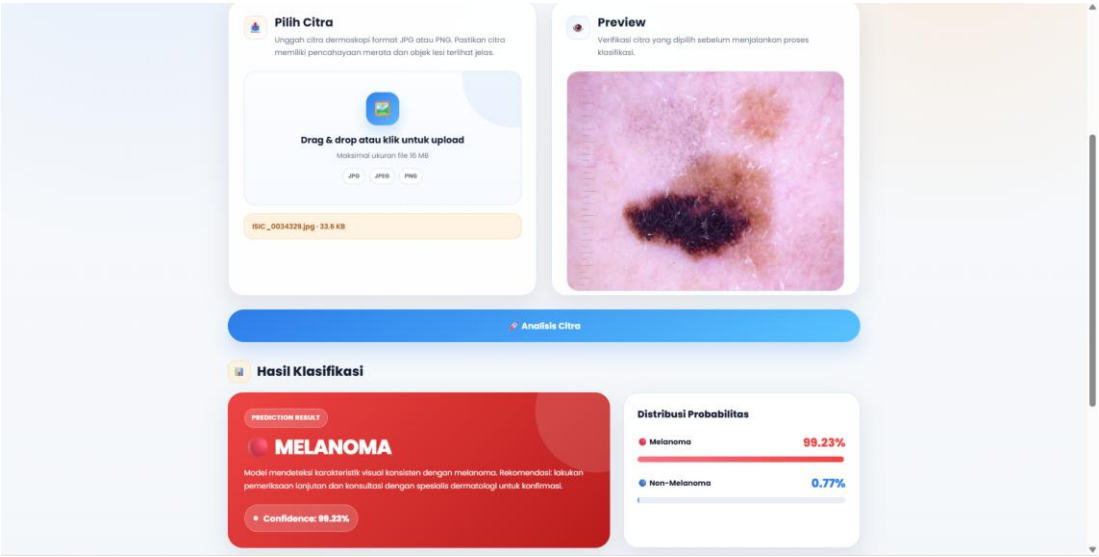
Model MobileNetV2 dimuat dari file bobot terbaik dan dijalankan dalam mode evaluasi. Untuk meningkatkan efisiensi, model disimpan dalam *cache* setelah pertama kali dimuat sehingga tidak perlu dilakukan proses *load* ulang pada setiap permintaan prediksi. Setelah citra melewati tahap preprocessing, model menghasilkan probabilitas untuk dua kelas, yaitu benign dan malignant. Kelas dengan nilai probabilitas tertinggi digunakan sebagai hasil prediksi akhir.

Hasil klasifikasi ditampilkan pada halaman web dalam bentuk label prediksi, yaitu Melanoma atau Non-Melanoma, disertai *confidence score* dan distribusi probabilitas masing-masing kelas. Jika model memprediksi citra sebagai melanoma, hasil ditampilkan dengan penanda warna merah. Sebaliknya, jika model memprediksi citra sebagai non-melanoma, hasil ditampilkan dengan penanda warna berbeda untuk memudahkan interpretasi pengguna. Tampilan halaman utama prototipe aplikasi web

ditunjukkan pada Gambar 4.15, sedangkan tampilan hasil prediksi ditunjukkan pada Gambar 4.16.



Gambar 4.15. Tampilan halaman utama MelanoLens



Gambar 4.16. Tampilan hasil klasifikasi pada MelanoLens

Selain fitur unggah dan klasifikasi citra, aplikasi juga menampilkan ringkasan metrik model terbaik, yaitu *accuracy*, *recall*, F1-*score*, dan AUC-ROC pada bagian utama halaman. Informasi ini bertujuan untuk memberikan gambaran singkat mengenai performa model yang digunakan dalam prototipe. Aplikasi juga menyediakan bagian informasi ABCDE sebagai edukasi awal mengenai karakteristik visual lesi kulit yang perlu diperhatikan. Namun, sistem tetap menyertakan disclaimer

bahwa hasil prediksi AI bersifat sebagai alat bantu dan bukan pengganti pemeriksaan klinis oleh tenaga medis.

Berdasarkan pengujian tambahan menggunakan beberapa gambar di luar ruang lingkup penelitian, seperti gambar yang bukan merupakan lesi kulit atau bukan citra dermoskopi, sistem tetap menghasilkan salah satu kelas prediksi. Kondisi ini terjadi karena model klasifikasi biner tidak memiliki kelas khusus untuk menolak gambar di luar domain penelitian. Dengan demikian, setiap input yang diberikan ke sistem akan tetap dipetakan ke salah satu dari dua kelas yang tersedia, yaitu melanoma atau non-melanoma. Pada beberapa gambar di luar domain, model juga dapat menghasilkan confidence score yang tinggi, sehingga confidence score tidak dapat digunakan sebagai indikator bahwa gambar masukan sudah sesuai dengan karakteristik data pelatihan.

Secara keseluruhan, implementasi prototipe aplikasi web MelanoLens menunjukkan bahwa model klasifikasi melanoma hasil penelitian dapat diintegrasikan ke dalam sistem berbasis web. Prototipe ini memungkinkan pengguna mengunggah citra dermoskopi, memperoleh hasil klasifikasi, serta melihat confidence score dan distribusi probabilitas secara langsung melalui antarmuka yang sederhana dan mudah digunakan. Namun, sistem ini hanya dirancang untuk citra dermoskopi lesi kulit sesuai dengan ruang lingkup penelitian. Apabila gambar yang diunggah berada di luar domain tersebut, model tetap dapat menghasilkan prediksi melanoma atau non-melanoma karena menggunakan pendekatan klasifikasi biner. Oleh karena itu, hasil prediksi hanya dapat diinterpretasikan apabila citra masukan sesuai dengan karakteristik data pelatihan.

BAB V
KESIMPULAN DAN SARAN

5.1 KESIMPULAN

Berdasarkan hasil penelitian yang telah dilakukan, kesimpulan yang dapat diambil adalah sebagai berikut:

1. Empat skenario klasifikasi melanoma berhasil diimplementasikan menggunakan dua arsitektur *lightweight* CNN, yaitu EfficientNet-B0 dan MobileNetV2, pada dua kondisi dataset, yaitu citra *original* dan citra hasil *digital hair removal*. Seluruh model dilatih menggunakan dataset ISIC 2019 dan ISIC 2020 yang telah melalui tahapan praproses, pembagian dataset secara *stratified*, normalisasi citra, dan augmentasi data. Implementasi menghasilkan empat model, yaitu EfficientNet-B0 *Original*, EfficientNet-B0 *Hair Removed*, MobileNetV2 *Original*, dan MobileNetV2 *Hair Removed*.
2. Evaluasi kinerja menunjukkan bahwa MobileNetV2 *Original* memberikan performa klasifikasi terbaik dengan *accuracy* sebesar 87,02%, *precision* sebesar 0,6524, *recall* sebesar 0,8796, F1-*score* sebesar 0,7492, dan AUC-ROC sebesar 0,9433. Dari sisi efisiensi komputasi, EfficientNet-B0 memiliki waktu inferensi tercepat sebesar 19,996 ms per citra, sedangkan MobileNetV2 *Original* membutuhkan 26,698 ms per citra. Hasil *confusion matrix* menunjukkan bahwa seluruh model memiliki kemampuan yang baik dalam mendeteksi melanoma, meskipun terdapat perbedaan performa pada masing-masing skenario eksperimen.
3. Penerapan *digital hair removal* memberikan dampak yang berbeda pada setiap arsitektur. Pada EfficientNet-B0, *digital hair removal* memberikan peningkatan performa dengan kenaikan *accuracy* dari 83,28% menjadi 84,08%, *precision* dari 0,5768 menjadi 0,5928, *specificity* dari 81,25% menjadi 82,80%, dan F1-*score* dari 0,7044 menjadi 0,7104. Sebaliknya, pada MobileNetV2, *digital hair removal* menyebabkan penurunan performa yang cukup signifikan, ditunjukkan oleh penurunan *accuracy* dari 87,02% menjadi 59,98%, *precision* dari 0,6524 menjadi 0,3472, dan F1-*score* dari 0,7492

menjadi 0,5053. Hasil ini menunjukkan bahwa efektivitas *digital hair removal* sangat dipengaruhi oleh karakteristik arsitektur CNN yang digunakan.

4. Prototipe aplikasi web berbasis Flask berhasil dikembangkan dengan mengintegrasikan model terbaik hasil penelitian, yaitu MobileNetV2 Original. Aplikasi yang diberi nama MelanoLens mampu menerima input citra dermoskopi, melakukan proses klasifikasi secara otomatis, dan menampilkan hasil prediksi dalam bentuk kelas Melanoma atau Non-Melanoma, *confidence score*, serta distribusi probabilitas masing-masing kelas. Prototipe ini menunjukkan bahwa model yang dihasilkan dapat diimplementasikan ke dalam aplikasi berbasis web yang mudah digunakan sebagai alat bantu deteksi awal melanoma.

5.2 SARAN

Berdasarkan hasil penelitian dan keterbatasan yang ditemukan selama penelitian, beberapa saran untuk penelitian selanjutnya adalah sebagai berikut:

1. Menggunakan metode *digital hair removal* yang lebih adaptif agar mampu menghilangkan rambut yang tebal, padat, atau saling bertumpuk tanpa mengurangi detail tekstur lesi yang penting untuk proses klasifikasi.
2. Mengeksplorasi arsitektur deep learning yang lebih modern, seperti EfficientNetV2, ConvNeXt, Vision Transformer (ViT), atau MobileViT, untuk mengetahui potensi peningkatan performa klasifikasi melanoma pada citra dermoskopi.
3. Melakukan pengujian menggunakan dataset dermoskopi lain dari sumber yang berbeda guna mengevaluasi kemampuan generalisasi model terhadap variasi karakteristik citra yang lebih beragam.
4. Mengembangkan prototipe MelanoLens dengan menambahkan fitur segmentasi lesi, visualisasi area perhatian model, serta integrasi dengan layanan cloud sehingga dapat digunakan secara lebih luas pada perangkat yang berbeda.
5. Menambahkan mekanisme validasi kualitas citra sebelum proses klasifikasi untuk memastikan bahwa gambar yang diunggah benar-benar merupakan citra

dermoskopi dengan kualitas yang memadai sehingga dapat mengurangi kesalahan prediksi akibat input yang tidak sesuai.

DAFTAR KEPUSTAKAAN

Al-Waisy, A. S., Al-Fahdawi, S., Khalaf, M. I., Mohammed, M. A., Al-Attar, B., & Al-Andoli, M. N. (2025). A deep learning framework for automated early diagnosis and classification of skin cancer lesions in dermoscopy images. *Scientific Reports*, *15*(1), 31234. https://doi.org/10.1038/s41598-025-15655-9

Arnold, M., Singh, D., Laversanne, M., Vignat, J., Vaccarella, S., Meheus, F., Cust, A. E., de Vries, E., Whiteman, D. C., & Bray, F. (2022). Global Burden of Cutaneous Melanoma in 2020 and Projections to 2040. *JAMA Dermatology*, *158*(5), 495–503. https://doi.org/10.1001/jamadermatol.2022.0160

Askale, G. T., Yibel, A. B., Munie, A. T., Areru, S. B., & Debasu, M. A. (2026). A customized MobileNetV2-based lightweight CNN for monkeypox detection and classification. *Scientific Reports*, *16*(1), 5028. https://doi.org/10.1038/s41598-026-35871-1

Codella, N. C. F., Gutman, D., Celebi, M. E., Helba, B., Marchetti, M. A., Dusza, S. W., Kalloo, A., Liopyris, K., Mishra, N., Kittler, H., & Halpern, A. (2018). *Skin Lesion Analysis Toward Melanoma Detection: A Challenge at the 2017 International Symposium on Biomedical Imaging (ISBI), Hosted by the International Skin Imaging Collaboration (ISIC)*.

Delibasis, K., Moutselos, K., Vorgiazidou, E., & Maglogiannis, I. (2023). Automated hair removal in dermoscopy images using shallow and deep learning neural architectures. *Computer Methods and Programs in Biomedicine Update*, *4*, 100109. https://doi.org/10.1016/j.cmpbup.2023.100109

Ertürk Zararsız, G., Yerlitaş Taştan, S. I., Çelik Gürbulak, E., Erakcaoğlu, A., Yılmaz Işıkhan, S., Demirbaş, A., Ertaş, R., Eroğlu, İ., Korkmaz, S., Elmas, Ö. F., & Zararsız, G. (2025). Diagnosis melanoma with artificial intelligence systems: A meta-analysis study and systematic review. *Journal of the European Academy of Dermatology and Venereology*, *39*(11), 1912–1922. https://doi.org/10.1111/jdv.20781

Fajrina, A. N., Pradana, Z. H., Purnama, S. I., & Romadhona, S. (2024). Penerapan Arsitektur EfficientNet-B0 Pada Klasifikasi Leukimia Tipe Acute Lymphoblastik Leukimia. *Jurnal Riset Rekayasa Elektro*, *6*(1), 59. https://doi.org/10.30595/jrre.v6i1.22090

Ferlay J, Ervik M, Lam F, Laversanne M, Colombet M, Mery L, Piñeros M, Znaor A, Soerjomataram I, Bray F (2024). Global Cancer Observatory: Cancer Today. Lyon, France: International Agency for Research on Cancer. Available from: https://gco.iarc.who.int/today, accessed [05 03 2026]

Gao, Y., Jiang, Y., Peng, Y., Yuan, F., Zhang, X., & Wang, J. (2025). Medical Image Segmentation: A Comprehensive Review of Deep Learning-Based Methods. *Tomography*, *11*(5), 52. https://doi.org/10.3390/tomography11050052

Hernández-Pérez, C., Combalia, M., Podlipnik, S., Codella, N. C. F., Rotemberg, V., Halpern, A. C., Reiter, O., Carrera, C., Barreiro, A., Helba, B., Puig, S., Vilaplana, V., & Malvehy, J. (2024). BCN20000: Dermoscopic Lesions in the Wild. *Scientific Data*, *11*(1), 641. https://doi.org/10.1038/s41597-024-03387-w

Iqbal, J., Faisal, M., Ullah, S., Khan, Z. A., Ali, Z., & Bawari, N. zaman. (2025). Utilizing deep learning algorithms for the early identification and categorization of skin cancer. *Journal of Genetic Engineering and Biotechnology*, *23*(4), 100576. https://doi.org/10.1016/j.jgeb.2025.100576

Jütte, L., Patel, H., & Roth, B. (2024). Advancing dermoscopy through a synthetic hair benchmark dataset and deep learning-based hair removal. *Journal of Biomedical Optics*, *29*(11). https://doi.org/10.1117/1.JBO.29.11.116003

Kittler, H. (2021). Evolution of the Clinical, Dermoscopic and Pathologic Diagnosis of Melanoma. *Dermatology Practical & Conceptual*, *11*(Suppl 1), e2021163S. https://doi.org/10.5826/dpc.11S1a163S

Liu, R., Chen, Z., Yao, G., & Zhang, P. (2026). *Exploring the Challenge and Value of Deep Learning in Automated Skin Disease Diagnosis*.

Mienye, I. D., & Swart, T. G. (2024). A Comprehensive Review of Deep Learning: Architectures, Recent Advances, and Applications. *Information*, *15*(12), 755. https://doi.org/10.3390/info15120755

Mienye, I. D., Swart, T. G., Obaido, G., Jordan, M., & Ilono, P. (2025). Deep Convolutional Neural Networks in Medical Image Analysis: A Review. *Information*, *16*(3), 195. https://doi.org/10.3390/info16030195

Nirupama, & Virupakshappa. (2024). MobileNet-V2: An Enhanced Skin Disease Classification by Attention and Multi-Scale Features. *Journal of Imaging Informatics in Medicine*, *38*(3), 1734–1754. https://doi.org/10.1007/s10278-024-01271-y

Powers, D. M. W. (2020). *Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation*.

Pratiwi Tentriajaya, I. D. A. P., & Wijayakusuma, I. G. N. L. (2025). Eye Disease Classification Using EfficientNet-B0 Based on Transfer Learning. *Journal of Applied Informatics and Computing*, *9*(4), 1415–1422. https://doi.org/10.30871/jaic.v9i4.9743

Quishpe-Usca, A., Cuenca-Dominguez, S., Arias-Viñansaca, A., Bosmediano-Angos, K., Villalba-Meneses, F., Ramírez-Cando, L., Tirado-Espín, A., Cadena-Morejón, C., Almeida-Galárraga, D., & Guevara, C. (2024). The effect of hair removal and filtering on melanoma detection: a comparative deep learning study

with AlexNet CNN. *PeerJ Computer Science*, *10*, e1953. https://doi.org/10.7717/peerj-cs.1953

Rotemberg, V., Kurtansky, N., Betz-Stablein, B., Caffery, L., Chousakos, E., Codella, N., Combalia, M., Dusza, S., Guitera, P., Gutman, D., Halpern, A., Helba, B., Kittler, H., Kose, K., Langer, S., Lioprys, K., Malvehy, J., Musthaq, S., Nanda, J., … Soyer, H. P. (2021). A patient-centric dataset of images and metadata for identifying melanomas using clinical context. *Scientific Data*, *8*(1), 34. https://doi.org/10.1038/s41597-021-00815-z

Shahzaib, A., Siddiqui, A. B., Anjum, N., Rehman, M. U., & Ramzan, N. (2025). Hair removal and lesion segmentation of dermoscopic images for classification of skin cancer using deep neural networks. *Egyptian Informatics Journal*, *32*, 100844. https://doi.org/10.1016/j.eij.2025.100844

Sung, H., Ferlay, J., Siegel, R. L., Laversanne, M., Soerjomataram, I., Jemal, A., & Bray, F. (2021). Global Cancer Statistics 2020: GLOBOCAN Estimates of Incidence and Mortality Worldwide for 36 Cancers in 185 Countries. *CA: A Cancer Journal for Clinicians*, *71*(3), 209–249. https://doi.org/10.3322/caac.21660

Sutama, V. A., Wibowo, S. A., & Rahmania, R. (2020). Investigasi Pengaruh Step Training pada Metode Single Shot Multibox Detector untuk Marker dalam Teknologi Augmented Reality. *Jurnal Ilmiah FIFO*, *12*(1), 1. https://doi.org/10.22441/fifo.2020.v12i1.001

Tschandl, P., Rosendahl, C., & Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, *5*(1), 180161. https://doi.org/10.1038/sdata.2018.161

Ummah, K. R., Karlita, T., Sigit, R., Yuniarno, E. M., Purnama, I. K. E., & Purnomo, M. H. (2022). EFFECT OF IMAGE PRE-PROCESSING METHOD ON CONVOLUTIONAL NEURAL NETWORK CLASSIFICATION OF COVID-19 CT SCAN IMAGES. *International Journal of Innovative Computing, Information and Control*, *18*(6), 1895–1912. https://doi.org/10.24507/ijicic.18.06.1895

University of Colorado Anschutz Cancer Center. (2024). *Skin Cancer*. University of Colorado Anschutz Cancer Center. https://medschool.cuanschutz.edu/colorado-cancer-center/for-patients-families/cancers-we-treat/skin-cancer

Wang, X., & Li, H. (2023). Investigation of Deep Learning Based Semantic Segmentation Models for Autonomous Vehicles. *International Journal of Advanced Computer Science and Applications*, *14*(11). https://doi.org/10.14569/IJACSA.2023.0141136

Weiss, R., Karimijafarbigloo, S., Roggenbuck, D., & Rödiger, S. (2022). Applications of Neural Networks in Biomedical Data Analysis. *Biomedicines*, *10*(7). https://doi.org/10.3390/biomedicines10071469

BIODATA

Nama : Shofia Nurul Huda
Tempat, tanggal lahir : Langsa, 15 Januari 2005
Alamat : Lampuuk Tungkop Darussalam
Nama Ayah : Ismul Huda
Pekerjaan Ayah : Dosen
Nama Ibu : Fatilah Erni
Pekerjaan Ibu : Guru
Alamat Orang Tua : Lampuuk Tungkop Darussalam

Riwayat Pendidikan :

Jenjang	Nama Sekolah	Bidang	Tempat	Tahun Ijazah
SD	SD IT Al-Azhar Banda Aceh	-	Jl. Mutiara, Kec. Syiah Kuala, Kota Banda Aceh, Prov. Aceh 23115	2016
SLTP	MTS Insan Qur'ani	-	Jln. Banda Aceh-Medan Km. 12,5, Aneuk Batee, Kec. Suka Makmur, Kab. Aceh Besar 23361	2019
SLTA	SMA Negeri 5 Banda Aceh	IPA	Jl. Hamzah Fansuri No.3, Kopelma Darussalam, Kec. Syiah Kuala, Kota Banda Aceh 23111	2022

Banda Aceh, 03 Juli 2026

Shofia Nurul Huda
NPM. 2208107010015